


第4章 语料库与 语言知识库



4.1 基本概念

2/100

4.1 基本概念





4.1 基本概念

◆ 语料库(corpus)

- 语料库(corpus) 就是存放语言材料的仓库 (语言数据库)。
- 基于语料库进行语言学研究—语料库语言学
(corpus linguistics)



4.1 基本概念

◆ 语料库语言学

- 根据篇章材料对语言的研究称为语料库语言学。
— [Aijmer, 1991]
- 基于现实生活中语言运用的实例进行的语言研究称为语料库语言学。 — [McEnery, 1996]
- 以语料为语言描写的起点或以语料为验证有关语言的假说的方法称为语料库语言学。
— [Crystal, 1991]



4.1 基本概念

◆ 两种解释：

- ❖ 不是新术语：利用语料库对语言的某个方面进行研究，或者发现某些规律性知识。
- ❖ 是新术语：对现行语言学理论进行批评，提出新的理论。



4.1 基本概念

“语料库语言学已经成为语言研究的主流。基于语料库的研究不再是计算机专家的独有领域，它正在对语言研究的许多领域产生愈来愈大的影响。”

—J. Thomas 等人为祝贺语料库语言学的主要奠基人和倡导者 G. Leech 六十岁生日而出版的语料库语言学研究论文集的开场白 [丁信善，1998]。



4.1 基本概念

◆ 语料库语言学研究的内容：

- 语料库的建设与编纂
- 语料库的加工和管理技术
- 语料库的使用



4.2 语料库技术的发展

9/100



4.2 语料库技术的发展

◆ 三个阶段

❖ 20世纪50年代中期之前：早期

- 语料库在语言研究中被广泛使用：语言习得、方言学、语言教学、句法和语义、音系研究等



4.2 语料库技术的发展

❖ 1957~20世纪80年代初期：沉寂时期

- 1957年 Chomsky 的《句法理论》及其以后一系列著作的发表，根本改变了语料库语言学的发展状况。
- Chomsky 及其转换生成语法学派批判早期的语料库研究方法：
 - 基于语料库的研究方法有误
 - 语料的不充分性



4.2 语料库技术的发展

❖ 20世纪80年代以后：复苏与发展时期

➤ 特征之一：第二代语料库相继建成：

- 1983年英国Lancaster 大学建成 Lancaster-Oslo / Bergen Corpus (LOB语料库)：研究英国英语，500语篇，每个语篇约2000词。
- 法国国家科学研究中心与美国芝加哥大学联合建成法语语料库 (Tremor de la Langue Francaise, TLF语料库)：2000书面法语文本，1.5 亿词。

12/100



4.2 语料库技术的发展

- 芬兰赫尔辛基大学建成历史英语语料库(The Helsinki Corpus of Historical English): 850-1720年, 1600万词。
- 1988年伦敦大学建成国际英语语料库(The International Corpus of English, ICE): 语料来自所有英语国家, 各100万词, 1990—1993年, 口语和书面语各一半, 18 岁以上接受英语教育的成人。



4.2 语料库技术的发展

➤ 特征之二：基于语料库的研究项目增多

1981年至1991年的11年时间里，大约有480个语料研究项目得到资助，而在1959年至1980年20多年的时间里，只有140个基于语料的研究项目。



4.2 语料库技术的发展

◆ 语料库技术复苏的原因

- (1) 计算机的迅速发展;
- (2) 转换生成语言学派对语料库语言学的批判不都正确（如指责计算机分析语料是伪技术），有的是片面的甚至是错误的（如对语料数据价值的否定）。



4.3 国内语料库研究状况

16/100



4.3 国内语料库研究状况

- ◆ 武汉大学汉语现代文学作品语料库(1979年, 527万字)
- ◆ 北航现代汉语语料库(1983年, 2000万字)
- ◆ 北师大中学语文教材语料库(1983年, 106万字)
- ◆ 北京语言学院现代汉语词频统计语料库(1983年, 182万字)、目前北京语言大学正面向“一带一路”战略开展语料库研究和开发工作
- ◆ 1991年中国国家语言文字工作委员会开始建立国家级大型汉语语料库, 以推进汉语的词法、句法、语义和语用研究, 其计划规模将达7000万汉字
- ◆ 清华大学汉语歧义切分语料库(1998年, 1亿汉字), 后来在汉语树库、篇章语料库建设等方面做了大量研发工作

17/100



4.3 国内语料库研究状况

◆ 北京大学计算语言学研究

(<http://icl.pku.edu.cn/>)在俞士汶教授领导下建立的综合型语言知识库(简称CLKB)涵盖了词、词组、句子、篇章各单位和词法、句法、语义各层面，从汉语向多语言辐射，从通用领域深入到专业领域。CLKB是目前国际上规模最大且获得广泛认可的汉语语言知识资源。



4.3 国内语料库研究状况

- ◆ 山西大学、哈工大、苏州大学、东北大学、中科院自动化所、计算所、社科院语言所、科技部中信所和香港城市大学、香港理工大学、台湾中央研究院等相当一批大学和研究机构都对汉语语料库的建设做出了重要贡献。
- ◆ 新疆大学、新疆师范大学、内蒙古大学、内蒙古师范大学、西藏大学、西北民族大学、中央民族大学、社科院民族学与人类学研究所等院所研究和开发了我国少数民族语言的语料库。
- ◆ 若干公司

19/100



4.4 语料库的类型

20/100



4.4 语料库的类型

◆按内容构成和目的划分 (4种类型)

● 异质的 (heterogeneous) — [黄昌宁, 2002]

最简单的语料收集方法，没有事先规定和选材原则。

● 同质的 (homogeneous)

与“异质”正好相反，比如美国的TIPSTER项目只收集军事方面的文本。



4.4 语料库的类型

- 系统的(systematic)

充分考虑语料的动态和静态问题、代表性和平衡问题以及语料库的规模等问题。

- 专用的(specialized)

如：北美的人文科学语料库。



4.4 语料库的类型

◆ 按语言种类划分

- 单语的
- 双语的或多语的

篇章对齐 / 句子对齐 / 结构对齐

◆ 是否标注？

- 具有词性标注
- 句法结构信息标注(树库)
- 语义信息标注

两个术语：

- 生语料
- 熟语料

23/100



4.4 语料库的类型

◆平衡语料库

- 平衡语料库着重考虑语料的代表性与平衡性。
- 语料采集的七项原则：语料的真实性、可靠性、科学性、代表性、权威性、分布性和流通性。其中，语料的分布性还要考虑语料的科学领域分布、地域分布、时间分布和语体分布等。

—[张普, 2003]



4.4 语料库的类型

问题：

- (1) 各分布点所选取语料量的科学依据是什么？
- (2) 使用度是否真实地反映了语言的使用情况？



4.4 语料库的类型

◆ 平行语料库

两种含义：一种是指在同一种语言的语料上的平行，例如，“国际英语语料库”，共有20个平行的子语料库，分别来自以英语为母语或官方语言和主要语言的国家，如英国、美国、加拿大、澳大利亚、新西兰等。其平行性表现为语料选取的时间、对象、比例、文本数、文本长度等几乎是一致的。建库的目的是对不同国家的英语进行对比研究。



4.4 语料库的类型

另一种平行语料库是指在两种或多种语言之间的平行采样和加工，例如，机器翻译中的双语对齐语料库

C: 早晨好!

E: Good morning.

C: 您能给我一杯咖啡吗?

E: Could you give me a cup of coffee?

... ..

C: 早晨₁ 好₂ !₃

E: Good₂ morning₁ .₃



4.4 语料库的类型

merkezdiki d ölet apparatliri bilen jaylardiki d ölet apparatlrining xizmet hoquqi merkeznning bir tutash rehberlikide jaylarning teshebbuskarliqi we aktipliqini toluq jari qildurush prinsipi boyiche ayrilidu.

中央和地方的国家机构职权的划分，遵循在中央的统一领导下，充分发挥地方的主动性、积极性的原则。

madda jungxua xelq jumhuriyitide hemme millet bapbarawer.

中华人民共和国各民族一律平等。

herqandaq milletni kemsitish we ëzishni men'i qilidu, milletler ittipaqliqini buzidighan we milliy b ölg ünchilik qilidighan qilmishlarni men'i qilidu.

禁止对任何民族的歧视和压迫，禁止破坏民族团结和制造民族分裂的行为。

.....



4.4 语料库的类型

◆ 已有的双语资源

- 加拿大议会会议录 (Canadian Hansards) <http://www.isi.edu/natural-language/download/hansard/>
- 克姆尼茨英-德翻译语料库 (Chemnitz E-G Translation Corpus) <http://www.tu-chemnitz.de/phil/english/chairs/linguist/real/independent/transcorpus/index.htm>
- 英语-挪威语平行语料库 (ENPC) <https://www.hf.uio.no/ilos/english/services/omc/enpc/>
- 葡-英双向平行语料库 (Compara) <http://www.linguateca.pt/COMPARA/Welcome.html>
- 香港立法委员会会议记录 (Hong Kong Hansards) <http://catalog.ldc.upenn.edu/LDC2000T50>
- 香港新闻 (Hong Kong News)
- 香港法律 (Hong Kong Laws)

29/100




4.4 语料库的类型

◆ 共时语料库与历时语料库

➤ 共时语料库 是为了对语言进行共时(同一时段)研究而建立的语料库。研究大树的横断面所见的细胞和细胞关系，即研究一个共时平面中的元素与元素的关系。

4.4 语料库的类型

- **历时语料库** 是为了对语言进行历时研究而建立的语料库。研究大树的纵剖面所见的每个细胞和细胞关系的演变，即研究一个历时切面中元素与元素关系的演化。





4.4 语料库的类型

◆判断历时语料库的4条原则 — [张普, 2003]

- (1) 是否动态：语料库必须是开放的、动态的。
- (2) 文本是否具有量化的流通度属性：所有的语料都应来源于大众传媒，具有与传媒特色相应的流通度属性。其量化的属性值也是动态的。
- (3) 深加工是否基于动态的加工方法：随语料的动态变化采集，并进行动态地加工。
- (4) 是否取得动态的加工结果：语料的加工结果也应是动态的和历时的。



4.5 语料库建设中的问题

33/100



4.5 语料库建设中的问题

◆语料库设计需要考虑的问题

●静态与动态

一种主张认为，应建立动态的或监督语料库 (monitor corpus)：文本集的收集通常是随遇的，而不是平衡的。而另一种主张认为，应该建立相对静态的、平衡的。其实每种主张均与研究或应用目的密切相关。



4.5 语料库建设中的问题

- 代表性和平衡性

一个语料库具有代表性，是指在语料库上获得的分析结果可以概括成为这种语言整体或其指定部分的特性。

—[Leech, 1991]

问题： 如何达到不同部分之间的平衡？



4.5 语料库建设中的问题

- 规模

- 第一代语料库100万词次
- 1990s : 1000—2000 万词次小型的一般语料库
一般而言，在保证质量的前提下应足够大。

- 语料库的管理与维护

- 错误修正或改善
- 版本升级
- 语料库的检索系统、分析和处理工具的维护等



4.5 语料库建设中的问题

◆ 汉语语料库开发中存在的问题

❖ 语料库建设的规范问题

- ✧ 信息处理用GB13000.1 字符集汉字部件规范 1997.12.5 国家语委;
- ✧ GB12200.1-90 汉语信息处理词汇01部分: 基本术语国家技术监督局(1993);
- ✧ GB/T12200.2-94 汉语信息处理词汇02部分: 汉语和汉字国家技术监督局(1994);
- ✧ GB13715 信息处理用现代汉语分词规范。



4.5 语料库建设中的问题

问题：

- ◆ 分词标准已经确定和统一？
- ◆ 词类标记集被普遍采用和遵循？
- ◆ 文本属性规范在哪里？

... ..



4.5 语料库建设中的问题

❖ 产权保护和国家语料库建设问题

- ✧ 汉语语料库的知识产权包括两个方面：文本的知识产权和语料库的知识产权及其衍生产品。
- ✧ 语料库的知识产权却没有得到保护，至今在著作权法、语言文字法、计算机软件保护等相关法规和实施条例中语料库的知识产权都是空白。

4.5 语料库建设中的问题

国家语料库的建设、开发、保护应该是一种国家行为，在信息社会和数字化生存时代，我们要把语言资源的收集、保护、开发提高到一种对待国家资源的高度来认识。国家要像对待人力资源、地矿资源、国土资源、森林资源、水资源一样对待语言资源，语言资源是国家最重要的信息资源。语料库的建设、保护、开发要站在国家面向未来的一种战略决策高度，要作为一种对待国家资源的行为，才能得到法律的保护，纳入法制的轨道[张普，2003]。



~2018.3.1

40/100



4.6 典型语料库介绍

41/100



4.6 典型语料库介绍

◆ 布朗语料库 (Brown Corpus)

- 20世纪60s, Francis 和 Kucera 在布朗(Brown)大学建立, 是世界上第一个根据系统性原则采集样本的标准语料库, 100万词规模;
- 选自1961年美国人撰写出版的普通语体的文本;
- 15种题材, 共500个样本, 每个样本不少于2000词;
- 1961年布朗大学出版了当代英语词频词典;
- 1970s Greene 和 Rubin 设计了TAGGIT词性标注系统(词类标记81种, 上下文约束规则3300条), 自动标注正确率77%。



4.6 典型语料库介绍

◆ LLC口语语料库(London-Lund Corpus of Spoken English)

- 1960s 伦敦大学著名语言学家Quirk 组织，瑞典隆德(Lund)大学教授 Svartvik 主持录入计算机
- 2000 小时的对话和广播等口语素材
- 英语口语调查 (The Survey of Spoken English, SSE)于1981年完成，建成 London-Lund Corpus of Spoken English (LLC)
- 87个文本，每个文本约5000词，最终规模 50万词
- 5大类：面对面交谈；电话交谈；讨论；采访；辩论，未经准备的当众评论、论证、演讲，经准备的当众演讲
- 标注：语调、节律、关键词(语段)，词类、出现次数、搭配关系等

43/100



4.6 典型语料库介绍

◆ 朗文语料库 (Longman Corpus)

- 朗文语料库委员会 (Longman Corpus Committee)
- **January 1981- November 1990**
- 设计原则：(1) 尊重本族语言者的直觉和语料库权威；
(2) 向研究人员提供语料(英国50%，美国40%，
其它国家10%)；(3) 书面语。
- 选自1900～的20世纪英语：知识性(informative)文60%，
想象性(imaginative)文本40%
- 10个分布广泛的领域：自然和纯科学、应用科学、社会科学、世界事务等
- 2800 万词

44/100



4.6 典型语料库介绍

◆ 宾夕法尼亚大学 (UPenn) 树库(Tree Bank) (<http://www ldc.upenn.edu/>)

- 美国宾夕法尼亚大学计算机系 M. Marcus 教授主持
- 1993年完成约300万词次英语句子的语法结构标注
- 2000年完成第一版汉语树库，约10万词次，4185个句子
- Chinese Tree Bank (CTB) 中汉语词性(part-of-speech)被划分为33类，23类句法标记(Syntactic tags)



4.6 典型语料库介绍


◆ **例句：**他还提出一系列具体措施的政策要点。

分词标注：他/PN 还/AD 提出/VV 一/CD 系列/M
具体/JJ 措施/NN 和/CC 政策/NN 要点/NN 。/PU

4.6 典型语料库介绍

标注: (IP (NP-SBJ (PN 他))
 (VP (ADVP (AD 还))
 (VP (VV 提出))
 (NP-OBJ (QP (CD 一)
 (CLP (M 系列)))
 (NP (NP (ADJP (JJ 具体)
 (NP (NN 措施))))
 (CC 和)
 (NP (NN 政策)
 (NN 要点))))))))))
 (PU 。))

4.6 典型语料库介绍





4.6 典型语料库介绍

◆宾夕法尼亚大学树库的扩展

(1) PropBank (Proposition Bank)

起初是在 Upenn 英语树库(English Treebank)的基础上增加语义信息后构建的“命题库”，其基本观点认为：树库仅提供句子的句法结构信息，对于计算机理解人类语言是不够的。因此，PropBank 的目标是对原树库中的句法节点标注上特定的论元标记(argument label)，使其保持语义角色的相似性。



4.6 典型语料库介绍

例如, *John broke the window.*

- 事件是 “打碎 (breaking event)”
- *John* 为事件的 制造者 (instigator)
- *window* 为 受事者 (patient)
- 窗户被打碎 (broken window) 为事件的结果

请看 PropBank 中标注的句子:

外商投资企业在改善中国出口商品结构中发挥了显著作用。