

隐马尔可夫模型及其应用

孙晓 合肥工业大学

计算机与信息学院 情感计算研究所

sunx@hfut.edu.cn

语音识别



机器翻译与OCR



隐马尔可夫模型

SHOWTIME

隐马尔可夫模型

◆ 隐马尔可夫模型可以表示为一个五元组(S, O, A, B, π)

- S 是一组状态的集合。 (四个杯子集合)

$$S = \{ 'S', 'I', 'B', 'E' \}$$

- O 是一组输出符号的集合。 (夹子的颜色集合)

$$O = \{ \text{红}, \text{蓝}, \text{绿}, \text{黄} \}$$

- A 是状态转移矩阵。 (杯子之间的转移概率分布)

$$A = [a_{ij}]$$

- B 是输出符号概率分布 (某个杯子取夹子颜色分布)

$$B = \{ P(v_k | j) \} \quad P(v_k | j) \text{ 表示在状态 } j \text{ 时输出符号 } v_k \text{ 的概率}$$

- π 是初始状态概率分布 $\pi = \{ \pi_i \}$ (初始取某个杯子的概率)

$$\pi_i = P(q_1 = i) \text{ 表示初始选择某个状态的概率。}$$

隐马尔可夫模型的三个应用

- ◆ 根据已有知识库，求得模型参数。
(学习或训练)
- ◆ 给定模型参数，计算观察序列 O 的概率。
(评估)
- ◆ 给定模型参数，和观察序列 O ，寻找一个状态转换序列 q ，
使该状态转换序列 q 最有可能产生观察序列 O 。
(解码)

中文分词问题



欢迎新老师生前来就餐




欢迎 新老 师生 前来 就餐



出现在合工大食堂外

B E S B I E B E S



中文分词知识库

方案：知识库→模型参数→中文分词

语料：

我 爱 你 程序员

他们 两个 人 是 半斤八两

角色标记：

我 爱 你 程序员

S S S B I E

他们 两个 人 是 半斤八两

B E B E S S B I I E

隐马尔可夫模型的参数

◆ 隐马尔可夫模型五元组(S, O, A, B, π)

- S 是一组状态的集合。

$$S = \{S, I, B, E\}$$

(汉字的四个角色)

- O 是一组

$$O = \{我, S, S, S, B, I, E\}$$

(6个汉字)

- A 是状态

$$A = [a_{ij}]$$

(SIBE角色之间的转移分布)

$$S \rightarrow S \quad S \rightarrow B$$

$$P(S \rightarrow S) = 3/5 \quad P(S \rightarrow B) = 2/5$$

$$I \rightarrow E \quad I \rightarrow I$$

$$P(I \rightarrow E) = ?? \quad P(I \rightarrow I) = ??$$

$$B \rightarrow I \quad B \rightarrow E$$

$$P(B \rightarrow I) = ?? \quad P(B \rightarrow E) = ??$$

$$E \rightarrow B \quad E \rightarrow S$$

$$P(E \rightarrow B) = ?? \quad P(E \rightarrow S) = ??$$

隐马尔可夫模型的参数

- B 是输出符号概率分布 (对应某个角色输出汉字的分布)
 $B = \{P(v_k | j)\}$ $P(v_k | j)$ 表示在状态 j 时输出符号 v_k 的概率

- π 是初始状态概率分布 (初始取哪个角色的概率)
 $\pi_i = P(q_1 = i)$ 的概率。

我	爱	你	程序员
S	S	S	B I E
他们	两个	人	是半斤八两
B E	B E	S	S B I I E

$P(\text{我} | S) = 1/5$
 $P(\text{爱} | S) = 1/5$
 $P(\text{你} | S) = 1/5$
 $P(\text{程} | B) = 1/4$

$\pi(S) = 1/2$
 $\pi(B) = 1/2$

隐马尔可夫模型的评价

模型的参数已知，评价某个分词结果

我 爱 你 程序员

S S S B I E

Value = $\frac{1}{2} * P(S \rightarrow S) * P(S \rightarrow S) * P(S \rightarrow B) * P(B \rightarrow I) * P(I \rightarrow E) *$


$P(\text{我} | S) * P(\text{爱} | S) * P(\text{你} | S) * P(\text{程} | B) * P(\text{序} | I) * P(\text{员} | S)$

隐马尔可夫模型解码

◆ 我爱人是程序员




求出SBESBIE



◆ 从所有可能的状态转换序列，求出最佳状态转换序列即为分词结果。

求解最佳状态转换序列

- ◆ 理论上，可以通过枚举所有的角色（状态）转换序列，并对每一个状态转换序列**评估**，取**评估值最大值**的状态转换序列就是可最好解释观察序列，即为**分词结果**。



总结

隐马尔可夫形象理解 → 状态转移不可见



隐马尔可夫模型的定义 → 五元组



隐马尔可夫模型的三个问题 → 参数估计，评价和解码



隐马尔可夫模型与中文分词 → 语料预处理

估计参数

评价分词结果

得到最优分词结果

思考



欢迎/新/老师/生前/来/就餐

结婚/的/和尚/未/结婚/的

邓颖/超生/前/用/的/物品

内塔尼亚/胡说...

根据碳碳键键能能否否定定律一

谢谢!