



合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

人工智能原理

刁云峰

计算机学院智能科学系

diaoyunfeng@hfut.edu.cn



期末报告作业要求：

1-5人为一组完成小组作业，后2周开始进行汇报展示（任选一个完成）

（1）翻译一篇人工智能顶会（CVPR,ICCV,ECCV,NIPS, ICLR, ICML, AAAI等）文献，并作PPT汇报讲解

（2）实现一个经典的AI或信息处理相关的项目，例如手写数字识别，目标检测等，做PPT汇报并进行demo展示

要求：

（1）一位同学进行全部汇报，或者分章节每位同学或多位同学进行汇报，汇报环节不强制要求每位同学都参加，参与汇报的同学视为加分项

（2）项目实现和文献翻译需要小组每位同学都参与完成（不强制要求每位同学都进行汇报）

备注：

（1）请在首页注明小组成员的学号姓名，PPT的最后注明每位同学的参与贡献。

（2）除上述两种形式的汇报外也可以进行其他形式的汇报，只要汇报内容与智能信息处理相关即可



合肥工业大学


HEFEI UNIVERSITY OF TECHNOLOGY

指导教材:

丛润民，李锋等，人工智能通识，机械工业出版社
李沐，动手学深度学习Pytorch版，人民邮电出版社

<https://tangshusen.me/Dive-into-DL-PyTorch/#/>

<https://space.bilibili.com/1567748478/channel/seriesdetail?sid=358497>





Artificial Intelligence

Artificial : 人工的，伪造的

Artificial Intelligence, 这个词非常中立客观，同时也避免了把人工智能约束在自动机或机器人领域，它涵盖了硬件实体的表现和程序软件的逻辑处理能力。

- Artificial一词的含义是人工的，伪造的。它的近义词是Man-made，反义词是Natural。
- 首先，人工智能必须是通过人为设定的方法和流程创造出来的智能体，而不可以是其他。
- 这就限定了人工智能不能是通过任何自然事件或自然程序产生的。比如图灵就曾提及，由人类女子分娩生产的婴儿是不在讨论范围之内的。
- 其次，在目前看，人工智能特指电子计算机技术创造出来的智能体，而类似人造胚胎、生物克隆等也不在人工智能讨论范围之内。



"Can machines think?"

机器能思考吗？

——艾伦·图灵

在这篇文章中，图灵针对机器是否能够模拟人类智能，表达了下面一些观点：

- 智能的模拟，根本在于机器是否能思考。
- 应该从科学客观的角度来评估机器是否能够思考，而不能陷入机器自身的主观感受的讨论。
- 机器应该是指电子计算机，讨论它是否能够根据程序表现出人类的智能。
- 计算机的智能不依赖于神学的上帝赐予灵魂。
- 计算机的程序逻辑也会有自身限制，但并不影响智能的表现，因为人类思维也有同样的限制。
- 计算机可以进行自我学习。
- 计算机模拟人类智能的任务，任重而道远。



合肥工业大学


HEFE

90年代的媒體：
人工智能會在十年內毀掉社會
現在的人工智能：






1. 人工智能简史-01-AI诞生-~1956
2. 人工智能简史-02-黄金时代-1956~1974
3. 人工智能简史-03-第一次寒冬-1974~1980
4. 人工智能简史-04-繁荣期-1980~1987
5. 人工智能简史-05-第二次寒冬-1987~1993
6. 人工智能简史-06-稳健时代-1993~2011
7. 人工智能简史-07-ABC时代-2012~
8. 人工智能简史-08-结语



大规模标注 标签处理



描述生成



视觉问答

Where is the child sitting?
fridge arms



视觉对话



多元智能



脑科学 行为学 社会学 认知学

情感智能

2009

2013

2014


2017

2018


2021

2022


手工特征提取



卷积神经网络



图卷积网络



大语言模型



视觉大模型



2005

2007

2012


2014

2017-2020


2022

2024


稀疏编码



对抗生成网络



Transformer/BERT



扩散模型





合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

课堂思政作业：人工智能合成内容（**AIGC**）有哪些应用场景，同时又有哪些安全风险？



空间滤波

输入

0	1	2
3	4	5
6	7	8

*

核

0	1
2	3

=

输出

19	25
37	43



空间滤波

2.6 卷积运算—纵向边缘检测

$$3 \times 1 + 1 \times 1 + 2 \times 1 + 0 \times 0 + 5 \times 0 + 7 \times 0 + 1 \times -1 + 8 \times -1 + 2 \times -1 = -5$$

3 ¹	0 ⁰	1 ⁻¹	2	7	4
1 ¹	5 ⁰	8 ⁻¹	9	3	1
2 ¹	7 ⁰	2 ⁻¹	5	1	3
0	1	3	1	7	8
4	2	1	6	2	8
2	4	5	2	3	9

6 X 6 X 1 灰度图像

Convolution卷积运算

*

1	0	-1
1	0	-1
1	0	-1

3 X 3

过滤器

Filter

卷积核

Kernel

=

-5			

4 X 4





合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

机器学习第一节 绪论




机器学习与人工智能、深度学习的关系

人工智能： 机器展现的人类智能

机器学习： 计算机利用已有的数据(经验)，得出了某种模型，并利用此模型预测未来的一种方法。

深度学习： 实现机器学习的一种技术






国内外知名人工智能企业榜单

编码	企业名称	人工智能技术	应用领域	所属国家	成立时间	资本市场状态	市值/估值/融资额
1	Microsoft（微软）	计算机视觉技术、自然语言处理技术等	办公	美国	1975年	上市	市值1.21万亿美元
2	Google（谷歌）	计算机视觉技术、自然语言处理技术等	综合	美国	1998年	上市	市值9324亿美元
3	Facebook（脸书）	人脸识别、深度学习等	社交	美国	2004年	上市	市值5934亿美元
4	百度	计算机视觉技术、自然语言处理技术、知识图谱等	综合	中国	2001年	上市	市值438亿美元
5	大疆创新	图像识别技术、智能引擎技术等	无人机	中国	2006年	战略融资	估值210亿美元
6	商汤科技	计算机视觉技术、深度学习	安防	中国	2014年	D轮融资	估值70亿美元
7	旷视科技	计算机视觉技术等	安防	中国	2011年	D轮融资	估值40亿美元
8	科大讯飞	智能语音技术	综合	中国	1999年	上市	市值108亿美元
9	Automation Anywhere	自然语言处理技术、非结构化数据认知	企业管理	美国	2003年	B轮融资	估值68亿美元
10	IBM Watson（IBM沃森）	深度学习、智适应学习技术	计算机	美国	1911年	上市	市值1198亿美元
11	松鼠AI 1对1	智适应学习技术、机器学习	教育	中国	2015年	A轮融资	估值11亿美元
12	字节跳动	跨媒体分析推理技术、深度学习、自然语言处理、图像识别	资讯	中国	2012年	Pre-IPO轮融资	估值750亿美元
13	Netflix（网飞）	视频图像优化、剧集封面图片个性化、视频个性化推荐	媒体及内容	美国	1997年	上市	市值1418亿美元
14	Graphcore	智能芯片技术、机器学习	芯片	英国	2016年	D轮融资	估值17亿美元
15	NVIDIA（英伟达）	智能芯片技术	芯片	美国	1993年	上市	市值1450亿美元
16	Brainco	脑机接口	教育、医疗、智能硬件	美国	2015年	天使轮融资	融资额600万美元
17	Waymo	自动驾驶	交通	美国	2016年	C轮融资	估值1050亿美元
18	ABB Robotics	机器人及自动化技术	机器人	瑞士	1988年	上市	市值514亿美元
19	Fanuc（发那科）	机器人技术	制造	日本	1956年	上市	市值362亿美元
20	Preferred Networks	深度学习、机器学习技术	物联网	日本	2016年	C轮融资	估值20亿美元



机器学习的范围



模式识别

计算机视觉



数据挖掘



机器学习

语音识别



统计学习



自然语言处理






机器学习可以解决什么问题

- 给定数据的预测问题
 - ✓ 数据清洗/特征选择
 - ✓ 确定算法模型/参数优化
 - ✓ 结果预测
- 不能解决什么
 - ✓ 大数据存储/并行计算
 - ✓ 做一个机器人



2. 机器学习的类型





2. 机器学习的类型-监督学习

- ✓ 分类 (Classification)

- ✓ 身高1.65m, 体重100kg的男人肥胖吗?

- ✓ 根据肿瘤的体积、患者的年龄来判断良性或恶性?

- ✓ 回归 (Regression、Prediction)

- ✓ 如何预测上海浦东的房价?

- ✓ 未来的股票市场走向?



2. 机器学习的类型-无监督学习

- ✓ 聚类 (Clustering)
 - ✓ 如何将教室里的学生按爱好、身高划分为5类?
- ✓ 降维 (Dimensionality Reduction)
 - ✓ 如何将原高维空间中的数据点映射到低维度的空间中?



合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

机器学习第二节

极大似然估计

Maximum likelihood estimation



机器学习/统计学习方法

刁云峰

LMC-媒体计算实验室




案例1：概率模型的训练过程（参数估计过程）





案例1：概率模型的训练过程（参数估计过程）

x_i



Cat(0)/Dog(1)

参数估计的两种解决思路：

- (1) 频率主义学派 (Frequentist) :
参数虽然未知，但却是客观存在的固定值 (极大似然估计)
- (2) 贝叶斯学派 (Bayesian) : 参数是未观察到的随机变量，其本身也有分布。



频率学派

频率学派（也称为传统学派）认为概率是一个长期的频率，即概率是某一事件在大量重复实验中发生的频率的极限。频率学派的核心思想是通过样本信息来推断总体信息，随着样本量的增加，推断的准确性会提高。代表性人物是[R.A.费希尔](#)。频率学派的主要方法和工具包括：

- **点估计**：使用极大似然估计（MLE）来估计未知参数。
- **置信区间**：通过样本数据计算总体参数的可能范围。
- **假设检验**：通过统计检验来判断某个假设是否成立。

贝叶斯学派

贝叶斯学派源于[托马斯·贝叶斯](#)在1763年发表的论文《论有关机遇问题的求解》。贝叶斯学派认为概率是主观信念，即对某一事件发生的不确定性程度的度量。贝叶斯学派的核心思想是通过先验信息和样本数据结合，通过[贝叶斯公式](#)更新对未知参数的信念。

区别和联系

频率学派和贝叶斯学派的主要区别在于对概率的解释和推断方法的不同：



- **概率解释**：频率学派认为概率是频率的极限，而贝叶斯学派认为概率是主观信念。
- **先验信息**：频率学派不使用先验信息，而贝叶斯学派强调先验信息的引入。
- **推断方法**：频率学派依赖样本数据和大数定律，而贝叶斯学派通过贝叶斯公式结合先验和样本数据进行推断。

在实际应用中，两个学派各有优缺点：

- **频率学派**适用于大量重复实验的情况，推断过程客观且可重复。
- **贝叶斯学派**适用于小样本或需要引入主观先验信息的情况，推断过程更加灵活和个性化。



《Pattern Recognition and Machine Learning》是由Christopher Bishop撰写的一本经典的机器学习教材。这本书全面介绍了模式识别和机器学习的基本概念、方法和应用，涵盖了从基础的概率分布、线性回归模型、线性分类模型到更复杂的神经网络、内核方法、图形模型等内容。书中强调了现代贝叶斯视角，并对概率图形模型和确定性推理方法等近期发展进行了全面介绍





PRML为何是机器学习的经典书籍中的经典？



LawrenceLauu, Researcher

1089 人赞同了该回答

PRML究竟有何过人之处，不能光看它本身的内容，最重要的是看其在Machine Learning, Data Mining这一类书籍中的地位。

通常从一个CS小白开始学Machine Learning或者Data Mining，到成长为一个独当一面的大牛，都会看几种类型的书：

- 以《数学之美⁺》为代表的科普类读物。通常作用为开发兴趣的。
- 《机器学习实战》、《推荐系统实践⁺》、《海量数据挖掘》等实践类书籍。在学中用，在用中学，实践中摸清套路。顺便了解一些基本模型。
- 《统计学习方法》、《数据挖掘导论⁺》、《数据挖掘（韩家炜）》等介绍类书籍。会对ML方面涉及到的技术做一个浅层次的介绍和全方位的了解，有少量数学内容和推导。
- 《PRML》、《ESL》、《MLAPP》这类进阶类书籍。包涵大量理论知识和数学推导（尤其是习题），有助于了解Machine Learning方法背后的本质和思想。

Machine Learning学习的过程，就是一个 **what -> how -> why** 的过程。而PRML，或者说同类的ESL等书籍，最大的作用就是让你知道**为什么会有这样的方法，为什么会有这样的模型，它背后的intuition⁺和motivation是什么**。而这恰恰是一个Machine Learning Researcher想要进一步使用模型、看懂别人paper中的模型、甚至自己提出新模型的基础。看PRML会带给你在Machine Learning上的理解和使用能力一个质的飞跃。

而在同一层次上，比如PRML和ESL相比，我个人认为，**PRML涵盖面更广，语言更通俗，例子和习题更加详细，附带更多基础性的讲解和指引（比如第二章整章都在介绍概率分布⁺），难度梯度设置更为合理**，是其深受广大中老年PHD朋友喜爱的原因。

可以说，PRML是一本兼顾**广度、深度、可读性、可用性（做习题）**的好书。



合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

Hands-on Bayesian Neural Networks – A Tutorial for Deep Learning Users

Laurent Valentin Jospin, University of Western Australia, Australia

Hamid Laga, Murdoch University, Australia

Farid Boussaid, University of Western Australia, Australia

Wray Buntine, Monash University, Australia

Mohammed Bennamoun, University of Western Australia, Australia



问题：现在你告诉了我一堆发生了的事情，怎么去确定参数让这堆事情发生的情况符合实际情况的概率最大呢？

解决方法

极大**似然**估计(Maximum likelihood estimation):
已知一堆数据，反推最具有可能（最大概率）导致这些样本结果出现的模型参数值！

刻画参数与数据的匹配程度!



Likelihood: how likely sth is to happen
可能，可能性，似然



案例2：在抛硬币实验中估计出现正面向上的概率 θ

假设已知的事件：扔了五次硬币，结果为1，0，0，1，1（三正两反）

问题：如何反推 θ ？



案例2：在抛硬币实验中估计出现正面向上的概率 θ

1. 确定概率模型

$$x_i = \begin{cases} 1, & \text{正面向上} \\ 0, & \text{反面向上} \end{cases} \quad x_i \sim B(1, \theta)$$

概率函数：

$$P(X = x) = \theta^x (1 - \theta)^{1-x}$$



在抛硬币实验中估计出现正面向上的概率 θ （未知）

假设已知的事件：扔了五次硬币，结果为1, 0, 0, 1, 1

问题：如何反推 θ ？

似然函数：

$$L_{(\theta)} = P(X_1 = x_1 | \theta) \dots P(X_n = x_n | \theta)$$
$$= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i}$$



似然函数: $L_{(\theta)} = P(X_1 = x_1|\theta) \dots P(X_n = x_n|\theta) = \prod_1^n \theta^{x_i}(1 - \theta)^{1-x_i}$

极大似然估计:
$$\max \ln L(\theta) = \sum_{i=1}^n [\ln \theta^{x_i} + \ln(1 - \theta)^{1-x_i}]$$

$$= \sum_{i=1}^n x_i \ln \theta + \left(n - \sum_{i=1}^n x_i \right) \ln(1 - \theta)$$



极大似然估计:

$$\max \ln L(\theta) = \sum_{i=1}^n [\ln \theta^{x_i} + \ln(1 - \theta)^{1-x_i}]$$

$$= \sum_{i=1}^n x_i \ln \theta + \left(n - \sum_{i=1}^n x_i \right) \ln(1 - \theta)$$

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{\sum_{i=1}^n x_i}{\theta} - \frac{n - \sum_{i=1}^n x_i}{1 - \theta} = 0$$

估计值:

$$\hat{\theta} = \frac{\sum_{i=1}^n x_i}{n}$$



问题：在抛硬币实验中估计出现正面向上的概率 θ


假设已知的事件：扔了五次硬币，结果为1, 0, 0, 1, 1

$$x_i = \begin{cases} 1, & \text{正面向上} \\ 0, & \text{反面向上} \end{cases}$$

估计值：

$$\hat{\theta} = \frac{\sum_{i=1}^n x_i}{n}$$

$$L(\theta) = P(X_1 = x_1 | \theta) \dots P(X_n = x_n | \theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i}$$





总结（似然函数的含义）：当一系列事实给定后，我们可以通过已经得知的事情发生情况去反推隐含的参数，使得在使用这些参数的情况下，事情按事实发生的概率最大（**刻画参数 θ 与数据的匹配程度**）

极大似然估计：

$$\begin{aligned}\max \ln L(\theta) &= \sum_{i=1}^n [\ln \theta^{x_i} + \ln(1 - \theta)^{1-x_i}] \\ &= \sum_{i=1}^n x_i \ln \theta + \left(n - \sum_{i=1}^n x_i \right) \ln(1 - \theta)\end{aligned}$$

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{\sum_{i=1}^n x_i}{\theta} - \frac{n - \sum_{i=1}^n x_i}{1 - \theta} = 0$$



本章总结

求解极大似然估计步骤

1. 写出似然函数

(1) 离散型统计模型:

$$L(\theta) = P(X_1 = x_1 | \theta) \dots P(X_n = x_n | \theta)$$

(2) 连续型统计模型:

$$L(\theta) = \int f(x; \theta) dx$$

2. 写出极大似然估计的对数形式

$$\max \ln L(\theta)$$

3. 解对数似然方程

$$\frac{\partial \ln L(\theta)}{\partial \theta} = 0 \quad \longrightarrow \quad \hat{\theta} = ?$$



合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

机器学习第三节


回归



线性回归

线性回归输出是一个连续值，因此适用于回归问题。回归问题在实际中很常见，如预测房屋价格、气温、销售额等连续值的问题。与回归问题不同，分类问题中模型的最终输出是一个离散值。我们所说的图像分类、垃圾邮件识别、疾病检测等输出为离散值的问题都属于分类问题的范畴。**softmax**回归则适用于分类问题。

由于线性回归和**softmax**回归都是单层神经网络，它们涉及的概念和技术同样适用于大多数的深度学习模型。我们首先以线性回归为例，介绍大多数深度学习模型的基本要素和表示方法。





3.1.1.1 模型定义

设房屋的面积为 x_1 ，房龄为 x_2 ，售出价格为 y 。我们需要建立基于输入 x_1 和 x_2 来计算输出 y 的表达式，也就是模型（model）。顾名思义，线性回归假设输出与各个输入之间是线性关系：

$$\hat{y} = x_1 w_1 + x_2 w_2 + b$$

其中 w_1 和 w_2 是权重（weight）， b 是偏差（bias），且均为标量。它们是线性回归模型的参数（parameter）。模型输出 $\hat{y}$ 是线性回归对真实价格 y 的预测或估计。我们通常允许它们之间有一定误差。



3.1.1.2 模型训练

接下来我们需要通过数据来寻找特定的模型参数值，使模型在数据上的误差尽可能小。这个过程叫作模型训练 (model training)。下面我们介绍模型训练所涉及的3个要素。

(1) 训练数据

我们通常收集一系列的真实数据，例如多栋房屋的真实售出价格和它们对应的面积和房龄。我们希望在这个数据上面寻找模型参数来使模型的预测价格与真实价格的误差最小。在机器学习术语里，该数据集被称为训练数据集 (training data set) 或训练集 (training set)，一栋房屋被称为一个样本 (sample)，其真实售出价格叫作标签 (label)，用来预测标签的两个因素叫作特征 (feature)。特征用来表征样本的特点。

假设我们采集的样本数为 n ，索引为 i 的样本的特征为 $x_1^{(i)}$ 和 $x_2^{(i)}$ ，标签为 $y^{(i)}$ 。对于索引为 i 的房屋，线性回归模型的房屋价格预测表达式为

$$\hat{y}^{(i)} = x_1^{(i)} w_1 + x_2^{(i)} w_2 + b$$



(2) 损失函数

$$\hat{y}^{(i)} = x_1^{(i)} w_1 + x_2^{(i)} w_2 + b$$

在模型训练中，我们需要衡量价格预测值与真实值之间的误差。通常会选取一个非负数作为误差，且数值越小表示误差越小。一个常用的选择是平方函数。它在评估索引为 i 的样本误差的表达式为

$$\ell^{(i)}(w_1, w_2, b) = \frac{1}{2} (\hat{y}^{(i)} - y^{(i)})^2$$

其中常数 $\frac{1}{2}$ 使对平方项求导后的常数系数为1，这样在形式上稍微简单一些。显然，误差越小表示预测价格与真实价格越相近，且当二者相等时误差为0。给定训练数据集，这个误差只与模型参数相关，因此我们把它记为以模型参数为参数的函数。在机器学习里，将衡量误差的函数称为损失函数（loss function）。这里使用的平方误差函数也称为平方损失（square loss）。

通常，我们用训练数据集中所有样本误差的平均来衡量模型预测的质量，即

$$\ell(w_1, w_2, b) = \frac{1}{n} \sum_{i=1}^n \ell^{(i)}(w_1, w_2, b) = \frac{1}{n} \sum_{i=1}^n \frac{1}{2} \left(x_1^{(i)} w_1 + x_2^{(i)} w_2 + b - y^{(i)} \right)^2$$

在模型训练中，我们希望找出一组模型参数，记为 w_1^*, w_2^*, b^* ，来使训练样本平均损失最小：

$$w_1^*, w_2^*, b^* = \arg \min_{w_1, w_2, b} \ell(w_1, w_2, b)$$



(3) 优化算法

当模型和损失函数形式较为简单时，上面的误差最小化问题的解可以直接用公式表达出来。这类解叫作解析解（analytical solution）。本节使用的线性回归和平方误差刚好属于这个范畴。然而，大多数深度学习模型并没有解析解，只能通过优化算法有限次迭代模型参数来尽可能降低损失函数的值。这类解叫作数值解（numerical solution）。

在求数值解的优化算法中，小批量随机梯度下降（mini-batch stochastic gradient descent）在深度学习中被广泛使用。它的算法很简单：先选取一组模型参数的初始值，如随机选取；接下来对参数进行多次迭代，使每次迭代都可能降低损失函数的值。在每次迭代中，先随机均匀采样一个由固定数目训练数据样本所组成的小批量（mini-batch） $\mathcal{B}$ ，然后求小批量中数据样本的平均损失有关模型参数的导数（梯度），最后用此结果与预先设定的一个正数的乘积作为模型参数在本次迭代的减小量。

在训练本节讨论的线性回归模型的过程中，模型的每个参数将作如下迭代：

$$\begin{aligned}w_1 &\leftarrow w_1 - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \frac{\partial \ell^{(i)}(w_1, w_2, b)}{\partial w_1} = w_1 - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} x_1^{(i)} \left(x_1^{(i)} w_1 + x_2^{(i)} w_2 + b - y^{(i)} \right), \\w_2 &\leftarrow w_2 - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \frac{\partial \ell^{(i)}(w_1, w_2, b)}{\partial w_2} = w_2 - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} x_2^{(i)} \left(x_1^{(i)} w_1 + x_2^{(i)} w_2 + b - y^{(i)} \right), \\b &\leftarrow b - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \frac{\partial \ell^{(i)}(w_1, w_2, b)}{\partial b} = b - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \left(x_1^{(i)} w_1 + x_2^{(i)} w_2 + b - y^{(i)} \right).\end{aligned}$$

在上式中， $|\mathcal{B}|$ 代表每个小批量中的样本个数（批量大小，batch size）， η 称作学习率（learning rate）并取正数。需要强调的是，这里的批量大小和学习率的值是人为设定的，并不是通过模型训练学出的，因此叫作超参数（hyperparameter）。我们通常所说的“调参”指的正是调节超参数，例如通过反复试错来找到超参数合适的值。在少数情况下，超参数也可以通过模型训练学出。本书对此类情况不做讨论。



3.1.1.3 模型预测

模型训练完成后，我们将模型参数 w_1, w_2, b 在优化算法停止时的值分别记作 $\hat{w}_1, \hat{w}_2, \hat{b}$ 。注意，这里我们得到的并不一定是最小化损失函数的最优解 w_1^*, w_2^*, b^* ，而是对最优解的一个近似。然后，我们就可以使用学出的线性回归模型 $x_1\hat{w}_1 + x_2\hat{w}_2 + \hat{b}$ 来估算训练数据集以外任意一栋面积（平方米）为 x_1 、房龄（年）为 x_2 的房屋的价格了。这里的估算也叫作模型预测、模型推断或模型测试。



1. 线性回归

01 线性回归




02 梯度下降

03 正则化

04 回归的评价指标



梯度下降





梯度下降的三种形式

批量梯度下降 (Batch Gradient Descent, BGD)

梯度下降的每一步中，都用到了所有的训练样本

随机梯度下降 (Stochastic Gradient Descent, SGD)

梯度下降的每一步中，用到一个样本，在每一次计算之后便更新参数，而不需要首先将所有的训练集求和

小批量梯度下降 (Mini-Batch Gradient Descent, MBGD)

梯度下降的每一步中，用到了一定批量的训练样本



梯度下降的三种形式

批量梯度下降 (Batch Gradient Descent)

梯度下降的每一步中，都用到了所有的训练样本

参数更新

学习率

梯度

$$w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^m \left((h(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)} \right)$$

(同步更新 w_j , $(j=0,1,...,n)$)



梯度下降的三种形式

随机梯度下降 (Stochastic Gradient Descent)

推导 $w = w - \alpha \cdot \frac{\partial J(w)}{\partial w}$ $h(x) = w^T X = w_0 x_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$

$$J(w) = \frac{1}{2} (h(x^{(i)}) - y^{(i)})^2$$

$$\frac{\partial}{\partial w_j} J(w) = \frac{\partial}{\partial w_j} \frac{1}{2} (h(x^{(i)}) - y^{(i)})^2 = 2 \cdot \frac{1}{2} (h(x^{(i)}) - y^{(i)}) \cdot \frac{\partial}{\partial w_j} (h(x^{(i)}) - y^{(i)})$$

$$= (h(x^{(i)}) - y^{(i)}) \cdot \frac{\partial}{\partial w_j} \left(\sum_{i=0}^n (w_i x_i^{(i)} - y^{(i)}) \right)$$

$$= (h(x^{(i)}) - y^{(i)}) x_j^{(i)}$$



梯度下降的三种形式

随机梯度下降 (Stochastic Gradient Descent)

梯度下降的每一步中，用到一个样本，在每一次计算之后便更新参数，而不需要首先将所有的训练集求和

参数更新

$$w_j := w_j - \alpha (h(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(同步更新 w_j , $(j=0,1,...,n)$)



梯度下降的三种形式

小批量梯度下降 (Mini-Batch Gradient Descent)

梯度下降的每一步中，用到了一定批量的训练样本

每计算常数 b 次训练实例，便更新一次参数 w

参数更新

$$w_j := w_j - \alpha \frac{1}{b} \sum_{k=i}^{i+b-1} (h(x^{(k)}) - y^{(k)}) x_j^{(k)}$$

(同步更新 w_j , $(j=0,1,...,n)$)

$b=1$ (随机梯度下降,SGD)
 $b=m$ (批量梯度下降,BGD)
 $b=batch_size$, 通常是2的指数倍, 常见有32,64,128等。(小批量梯度下降,MBGD)



梯度下降与最小二乘法比较

梯度下降： 需要选择学习率 α ，需要多次迭代，当特征数量 n 大时也能较好适用，适用于各种类型的模型。


最小二乘法： 不需要选择学习率 α ，一次计算得出，需要计算 $(X^T X)^{-1}$ ，如果特征数量 n 较大则运算代价大，因为矩阵逆的计算时间复杂度为 $O(n^3)$ ，通常来说当 n 小于10000 时还是可以接受的，只适用于线性模型，不适合逻辑回归模型等其他模型。




数据归一化/标准化

为什么要标准化/归一化？

提升模型精度：不同维度之间的特征在数值上有一定比较性，可以大大提高分类器的准确性。



加速模型收敛：最优解的寻优过程明显会变得平缓，更容易正确的收敛到最优解。





数据归一化/标准化

归一化（最大 - 最小规范化）

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

将数据映射到[0,1]区间

数据归一化的目的是使得各特征对目标变量的影响一致，会将特征数据进行伸缩变化，所以数据归一化是会改变特征数据分布的。

Z-Score标准化

$$x^* = \frac{x - \mu}{\sigma}$$

处理后的数据均值为0，方差为1

数据标准化为了不同特征之间具备可比性，经过标准化变换之后的特征数据分布没有发生改变。

就是当数据特征取值范围或单位差异较大时，最好是做一下标准化处理。

$$\sigma^2 = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \mu)^2$$
$$\mu = \frac{1}{m} \sum_{i=1}^m x^{(i)}$$



数据归一化/标准化

需要做数据归一化/标准化

线性模型，如基于距离度量的模型包括KNN(K近邻)、K-means聚类、感知机和SVM。另外，线性回归类的几个模型一般情况下也是**需要**做数据归一化/标准化处理的。

不需要做数据归一化/标准化

决策树、基于决策树的Boosting和Bagging等集成学习模型对于特征取值大小并不敏感，如随机森林、XGBoost、LightGBM等树模型，以及朴素贝叶斯，以上这些模型一般**不需要**做数据归一化/标准化处理。



3. 正则化

01 线性回归


02 梯度下降

03 正则化


04 回归的评价指标




过拟合和欠拟合



欠拟合



过拟合



正合适



过拟合的处理

1. 获得更多的训练数据

使用更多的训练数据是解决过拟合问题最有效的手段，因为更多的样本能够让模型学习到更多更有效的特征，减小噪声的影响。

2. 降维

即丢弃一些不能帮助我们正确预测的特征。可以是手工选择保留哪些特征，或者使用一些模型选择的算法来帮忙（例如PCA）。

3. 正则化


正则化(regularization)的技术，保留所有的特征，但是减少参数的大小（magnitude），它可以改善或者减少过拟合问题。

4. 集成学习方法

集成学习是把多个模型集成在一起，来降低单一模型的过拟合风险。



数据决定一切



通过这张图可以看出，各种不同算法在输入的数据量达到一定级数后，都有相近的高准确度。于是诞生了机器学习界的名言：

成功的机器学习应用不是拥有最好的算法，而是拥有最多的数据！



欠拟合的处理

1. 添加新特征

当特征不足或者现有特征与样本标签的相关性不强时，模型容易出现欠拟合。通过挖掘组合特征等新的特征，往往能够取得更好的效果。

2. 增加模型复杂度

简单模型的学习能力较差，通过增加模型的复杂度可以使模型拥有更强的拟合能力。例如，在线性模型中添加高次项，在神经网络模型中增加网络层数或神经元个数等。

3. 减小正则化系数

正则化是用来防止过拟合的，但当模型出现欠拟合现象时，则需要有针对性地减小正则化系数。



正则化

L1正则化: $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n |w_j|$, Lasso Regression (Lasso回归)

L2正则化: $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n w_j^2$, Ridge Regression (岭回归)

Elastic Net: $J(w) = \frac{1}{2} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda(\rho \cdot \sum_{j=1}^n |w_j| + (1 - \rho) \cdot \sum_{j=1}^n w_j^2)$
(弹性网络)




其中:

- λ 为正则化系数, 调整正则化项与训练误差的比例, $\lambda > 0$ 。
- $1 \geq \rho \geq 0$ 为比例系数, 调整L1正则化与L2正则化的比例。




正则化



L1正则化是指在损失函数中加入权值向量 $\mathbf{w}$ 的绝对值之和，L1的功能是使权重稀疏

L1正则化可以产生稀疏模型



在损失函数中加入权值向量 $\mathbf{w}$ 的平方和，L2的功能是使权重平滑。

L2正则化可以防止过拟合

图上面中的蓝色轮廓线是没有正则化损失函数的等高线，中心的蓝色点为最优解，左图、右图分别为L1、L2正则化给出的限制。

可以看到在正则化的限制之下，L1 正则化给出的最优解 $\mathbf{w}^*$ 是使解更加靠近原点,也就是说 L2 正则化能降低参数范数的总和。

L1正则化给出的最优解 $\mathbf{w}^*$ 是使解更加靠近某些轴,而其它的轴则为0,所以L1正则化能使得到的参数稀疏化。



4. 回归的评价指标

01 线性回归

02 梯度下降

03 正则化

04 回归的评价指标



回归的评价指标

均方误差 (Mean Square Error, MSE)

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$$

均方根误差 RMSE (Root Mean Square Error, RMSE)

$$\text{RMSE}(y, \hat{y}) = \sqrt{\frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}$$

平均绝对误差 (Mean Absolute Error, MAE)

$$\text{MAE}(y, \hat{y}) = \frac{1}{m} \sum_{i=1}^m |y^{(i)} - \hat{y}^{(i)}|$$

其中, $y^{(i)}$ 和 $\hat{y}^{(i)}$ 分别表示第 i 个样本的真实值和预测值, m 为样本个数。



回归的评价指标

R方 [*RSquared* (*r2score*)]

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^m (y^{(i)} - \bar{y})^2} = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^m (y^{(i)} - \frac{\hat{y}^{(i)}}{m})^2}{\sum_{i=1}^m (y^{(i)} - \frac{\bar{y}}{m})^2}$$
$$= 1 - \frac{MSE}{Var}$$

$$SSR = \sum_{i=1}^m (\hat{y}^{(i)} - \bar{y})^2$$
$$SSE = \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$$
$$SST = \sum_{i=1}^m (y^{(i)} - \bar{y})^2$$

越接近于1,说明模型拟合得越好

其中, $y^{(i)}$ 和 $\hat{y}^{(i)}$ 分别表示第*i*个样本的真实值和预测值, m 为样本个数。



概率扩散生成模型 (Diffusion Model)

扩散生成模型是属于一类基于似然函数的概率模型。通过逐步去噪，用正态分布 x_T 变量来学习数据 $p(x)$ ，即学习长度为 T 的固定的马尔可夫链的反向过程。

$$L_{DM} = \mathbb{E}_{x, \epsilon \sim \mathcal{N}(0,1), t} \left[\|\epsilon - \epsilon_{\theta}(x_t, t)\|_2^2 \right]$$

其中 t 从 $\{1, 2, \dots, T\}$ 中均匀采样，模型可以解释为去噪自编码器 $\epsilon_{\theta}(x_t, t)$ (ϵ_{θ} 通常使用U-Net)，通过训练来预测 x_t 的去噪版本，即 x_0 。扩散模型能够通过使用条件去噪自动编码器 $\epsilon_{\theta}(x_t, t, y)$ 来建模条件分布 $p(x|y)$

