



合肥工业大学


HEFEI UNIVERSITY OF TECHNOLOGY

卷积神经网络与图像 分类



1. 手工特征的图像分类方法介绍


Recap: Image Classification with Linear Classifier



$$f(x, W) = Wx + b$$


Algebraic Viewpoint

$$f(x, W) = Wx$$



Visual Viewpoint

One template per class



Geometric Viewpoint

Hyperplanes cutting up space






Image Classification: A core task in Computer Vision



[This image](#) by [Nikita](#) is
licensed under [CC-BY 2.0](#)

(assume given a set of labels)
{dog, cat, truck, plane, ...}




cat
dog
bird
deer
truck




Problem: Linear Classifiers are not very powerful

Visual Viewpoint



Linear classifiers learn
one template per class

Geometric Viewpoint



Linear classifiers can
only draw linear
decision boundaries



Pixel space




$$f(x) = Wx$$

Class
scores





Example: Color Histogram






Example: Histogram of Oriented Gradients (HoG)



Divide image into 8x8 pixel regions
Within each region quantize edge
direction into 9 bins



Example: 320x240 image gets divided
into 40x30 bins; in each bin there are 9
numbers so feature vector has $30 \times 40 \times 9 =$
10,800 numbers



2. 卷积神经网络









Image features vs. ConvNets



training

10 numbers giving scores for classes



Krizhevsky, Sutskever, and Hinton, "Imagenet classification with deep convolutional neural networks", NIPS 2012.
Figure copyright Krizhevsky, Sutskever, and Hinton, 2012.
Reproduced with permission.

10 numbers giving scores for classes

training





卷积层

5.1.1 二维互相关运算

虽然卷积层得名于卷积 (convolution) 运算, 但我们通常在卷积层中使用更加直观的互相关 (cross-correlation) 运算。在二维卷积层中, 一个二维输入数组和一个二维核 (kernel) 数组通过互相关运算输出一个二维数组。我们用一个具体例子来解释二维互相关运算的含义。如图5.1所示, 输入是一个高和宽均为3的二维数组。我们将该数组的形状记为 3×3 或 $(3, 3)$ 。核数组的高和宽分别为2。该数组在卷积计算中又称卷积核或过滤器 (filter)。卷积核窗口 (又称卷积窗口) 的形状取决于卷积核的高和宽, 即 2×2 。图5.1中的阴影部分为第一个输出元素及其计算所使用的输入和核数组元素: $0 \times 0 + 1 \times 1 + 3 \times 2 + 4 \times 3 = 19$ 。




图5.1 二维互相关运算

在二维互相关运算中, 卷积窗口从输入数组的最左上方开始, 按从左往右、从上往下的顺序, 依次在输入数组上滑动。当卷积窗口滑动到某一位置时, 窗口中的输入子数组与核数组按元素相乘并求和, 得到输出数组中相应位置的元素。图5.1中的输出数组高和宽分别为2, 其中的4个元素由二维互相关运算得出:

$$\begin{aligned}0 \times 0 + 1 \times 1 + 3 \times 2 + 4 \times 3 &= 19, \\1 \times 0 + 2 \times 1 + 4 \times 2 + 5 \times 3 &= 25, \\3 \times 0 + 4 \times 1 + 6 \times 2 + 7 \times 3 &= 37, \\4 \times 0 + 5 \times 1 + 7 \times 2 + 8 \times 3 &= 43.\end{aligned}$$



Pytorch卷积实现

```
import torch
from torch import nn
```

```
def corr2d(X, K): # 本函数已保存在d2lzh_pytorch包中方便以后使用
    h, w = K.shape
    Y = torch.zeros((X.shape[0] - h + 1, X.shape[1] - w + 1))
    for i in range(Y.shape[0]):
        for j in range(Y.shape[1]):
            Y[i, j] = (X[i: i + h, j: j + w] * K).sum()
    return Y
```

我们可以构造图5.1中的输入数组 X 、核数组 K 来验证二维互相关运算的输出。

```
X = torch.tensor([[0, 1, 2], [3, 4, 5], [6, 7, 8]])
K = torch.tensor([[0, 1], [2, 3]])
corr2d(X, K)
```

输出:

```
tensor([[19., 25.],
        [37., 43.]])
```

二维卷积层将输入和卷积核做互相关运算，并加上一个标量偏差来得到输出。卷积层的模型参数包括了卷积核和标量偏差。在训练模型的时候，通常我们先对卷积核随机初始化，然后不断迭代卷积核和偏差。

下面基于 `corr2d` 函数来实现一个自定义的二维卷积层。在构造函数 `__init__` 里我们声明 `weight` 和 `bias` 这两个模型参数。前向计算函数 `forward` 则是直接调用 `corr2d` 函数再加上偏差。

```
class Conv2D(nn.Module):
    def __init__(self, kernel_size):
        super(Conv2D, self).__init__()
        self.weight = nn.Parameter(torch.randn(kernel_size))
        self.bias = nn.Parameter(torch.randn(1))

    def forward(self, x):
        return corr2d(x, self.weight) + self.bias
```

python

卷积窗口形状为 $p \times q$ 的卷积层称为 $p \times q$ 卷积层。同样， $p \times q$ 卷积或 $p \times q$ 卷积核说明卷积核的高和宽分别为 p 和 q 。



Conv2d

Conv

+ Conv

```
CLASS torch.nn.quantized.Conv2d(in_channels, out_channels, kernel_size,  
    stride=1, padding=0, dilation=1, groups=1, bias=True,  
    padding_mode='zeros', device=None, dtype=None) [SOURCE]
```

Applies a 2D convolution over a quantized input signal composed of several quantized input planes.

For details on input arguments, parameters, and implementation see [Conv2d](#).

• NOTE

Only `zeros` is supported for the `padding_mode` argument.

• NOTE

Only `torch.quint8` is supported for the input data type.



5.2 填充和步幅

在上一节的例子里，我们使用高和宽为3的输入与高和宽为2的卷积核得到高和宽为2的输出。一般来说，假设输入形状是 $n_h \times n_w$ ，卷积核窗口形状是 $k_h \times k_w$ ，那么输出形状将会是

$$(n_h - k_h + 1) \times (n_w - k_w + 1).$$

所以卷积层的输出形状由输入形状和卷积核窗口形状决定。本节我们将介绍卷积层的两个超参数，即填充和步幅。它们可以对给定形状的输入和卷积核改变输出形状。

输入		核		输出																	
<table border="1"><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>3</td><td>4</td><td>5</td></tr><tr><td>6</td><td>7</td><td>8</td></tr></table>	0	1	2	3	4	5	6	7	8	*	<table border="1"><tr><td>0</td><td>1</td></tr><tr><td>2</td><td>3</td></tr></table>	0	1	2	3	=	<table border="1"><tr><td>19</td><td>25</td></tr><tr><td>37</td><td>43</td></tr></table>	19	25	37	43
0	1	2																			
3	4	5																			
6	7	8																			
0	1																				
2	3																				
19	25																				
37	43																				



5.2.1 填充

填充 (padding) 是指在输入高和宽的两侧填充元素 (通常是0元素)。图5.2里我们在原输入高和宽的两侧分别添加了值为0的元素, 使得输入高和宽从3变成了5, 并导致输出高和宽由2增加到4。图5.2中的阴影部分为第一个输出元素及其计算所使用的输入和核数组元素: $0 \times 0 + 0 \times 1 + 0 \times 2 + 0 \times 3 = 0$ 。




图5.2 在输入的高和宽两侧分别填充了0元素的二维互相关计算

一般来说, 如果在高的两侧一共填充 p_h 行, 在宽的两侧一共填充 p_w 列, 那么输出形状将会是

$$(n_h - k_h + p_h + 1) \times (n_w - k_w + p_w + 1),$$

也就是说, 输出的高和宽会分别增加 p_h 和 p_w 。

在很多情况下, 我们会设置 $p_h = k_h - 1$ 和 $p_w = k_w - 1$ 来使输入和输出具有相同的高和宽。这样会方便在构造网络时推测每个层的输出形状。假设这里 k_h 是奇数, 我们会在高的两侧分别填充 $p_h/2$ 行。如果 k_h 是偶数, 一种可能是在输入的顶端一侧填充 $\lceil p_h/2 \rceil$ 行, 而在底端一侧填充 $\lfloor p_h/2 \rfloor$ 行。在宽的两侧填充同理。



5.2.2 步幅

在上一节里我们介绍了二维互相关运算。卷积窗口从输入数组的最左上方开始，按从左往右、从上往下的顺序，依次在输入数组上滑动。我们将每次滑动的行数和列数称为步幅 (stride)。

目前我们看到的例子里，在高和宽两个方向上步幅均为1。我们也可以使用更大步幅。图5.3展示了在高上步幅为3、在宽上步幅为2的二维互相关运算。可以看到，输出第一列第二个元素时，卷积窗口向下滑动了3行，而在输出第一行第二个元素时卷积窗口向右滑动了2列。当卷积窗口在输入上再向右滑动2列时，由于输入元素无法填满窗口，无结果输出。图5.3中的阴影部分为输出元素及其计算所使用的输入和核数组元素： $0 \times 0 + 0 \times 1 + 1 \times 2 + 2 \times 3 = 8$ 、 $0 \times 0 + 6 \times 1 + 0 \times 2 + 0 \times 3 = 6$ 。




图5.3 高和宽上步幅分别为3和2的二维互相关运算

一般来说，当高上步幅为 s_h ，宽上步幅为 s_w 时，输出形状为

$$\lfloor (n_h - k_h + p_h + s_h) / s_h \rfloor \times \lfloor (n_w - k_w + p_w + s_w) / s_w \rfloor.$$



Copy to clipboard

```
import torch
from torch import nn

# 定义一个函数来计算卷积层。它对输入和输出做相应的升维和降维
def comp_conv2d(conv2d, X):
    # (1, 1)代表批量大小和通道数 (“多输入通道和多输出通道”一节将介绍) 均为1
    X = X.view((1, 1) + X.shape)
    Y = conv2d(X)
    return Y.view(Y.shape[2:]) # 排除不关心的前两维: 批量和通道

# 注意这里是两侧分别填充1行或列, 所以在两侧一共填充2行或列
conv2d = nn.Conv2d(in_channels=1, out_channels=1, kernel_size=3, padding=1)

X = torch.rand(8, 8)
comp_conv2d(conv2d, X).shape
```

输出:

$$\lfloor (n_h - k_h + p_h + s_h) / s_h \rfloor \times \lfloor (n_w - k_w + p_w + s_w) / s_w \rfloor.$$

```
torch.Size([8, 8])
```



5.3.1 多输入通道

当输入数据含多个通道时，我们需要构造一个输入通道数与输入数据的通道数相同的卷积核，从而能够与含多通道的输入数据做互相关运算。假设输入数据的通道数为 c_i ，那么卷积核的输入通道数同样为 c_i 。设卷积核窗口形状为 $k_h \times k_w$ 。当 $c_i = 1$ 时，我们知道卷积核只包含一个形状为 $k_h \times k_w$ 的二维数组。当 $c_i > 1$ 时，我们将会为每个输入通道各分配一个形状为 $k_h \times k_w$ 的核数组。把这 c_i 个数组在输入通道维上连结，即得到一个形状为 $c_i \times k_h \times k_w$ 的卷积核。由于输入和卷积核各有 c_i 个通道，我们可以在各个通道上对输入的二维数组和卷积核的二维核数组做互相关运算，再将这 c_i 个互相关运算的二维输出按通道相加，得到一个二维数组。这就是含多个通道的输入数据与多输入通道的卷积核做二维互相关运算的输出。

图5.4展示了含2个输入通道的二维互相关计算的例子。在每个通道上，二维输入数组与二维核数组做互相关运算，再按通道相加即得到输出。图5.4中阴影部分为第一个输出元素及其计算所使用的输入和核数组元素： $(1 \times 1 + 2 \times 2 + 4 \times 3 + 5 \times 4) + (0 \times 0 + 1 \times 1 + 3 \times 2 + 4 \times 3) = 56$ 。





图5.4 含2个输入通道的互相关计算



池化层

- makes the representations smaller and more manageable
- operates over each activation map independently





MAX POOLING

Single depth slice

x ↑

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

→ y

max pool with 2x2 filters
and stride 2




6	8
3	4

- No learnable parameters
- Introduces spatial invariance



Fully Connected Layer (FC layer)


- Contains neurons that connect to the entire input volume, as in ordinary Neural Networks






3. 常见的卷积神经网络

LeNet





```

LeNet(
  (conv): Sequential(
    (0): Conv2d(1, 6, kernel_size=(5, 5), stride=(1, 1))
    (1): Sigmoid()
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (3): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))
    (4): Sigmoid()
    (5): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (fc): Sequential(
    (0): Linear(in_features=256, out_features=120, bias=True)
    (1): Sigmoid()
    (2): Linear(in_features=120, out_features=84, bias=True)
    (3): Sigmoid()
    (4): Linear(in_features=84, out_features=10, bias=True)
  )
)

```

$$\lfloor (n_h - k_h + p_h + s_h) / s_h \rfloor \times \lfloor (n_w - k_w + p_w + s_w) / s_w \rfloor.$$

```
import time
import torch
from torch import nn, optim

import sys
sys.path.append("../")
import d2lzh_pytorch as d2l

device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')


class LeNet(nn.Module):
    def __init__(self):
        super(LeNet, self).__init__()
        self.conv = nn.Sequential(
            nn.Conv2d(1, 6, 5), # in_channels, out_channels, kernel_size
            nn.Sigmoid(),
            nn.MaxPool2d(2, 2), # kernel_size, stride
            nn.Conv2d(6, 16, 5),
            nn.Sigmoid(),
            nn.MaxPool2d(2, 2)
        )
        self.fc = nn.Sequential(
            nn.Linear(16*4*4, 120),
            nn.Sigmoid(),
            nn.Linear(120, 84),
            nn.Sigmoid(),
            nn.Linear(84, 10)
        )

    def forward(self, img):
        feature = self.conv(img)
        output = self.fc(feature.view(img.shape[0], -1))
        return output
```



3. 常见的卷积神经网络

AlexNet





诞生背景：

我们在上一节看到，神经网络可以直接基于图像的原始像素进行分类。这种称为端到端（end-to-end）的方法节省了很多中间步骤。然而，在很长一段时间里更流行的是研究者通过勤劳与智慧所设计并生成的人工特征。这类图像分类研究的主要流程是：

1. 获取图像数据集；
2. 使用已有的特征提取函数生成图像的特征；
3. 使用机器学习模型对图像的特征分类。

当时认为的机器学习部分仅限最后这一步。如果那时候跟机器学习研究者交谈，他们会认为机器学习既重要又优美。优雅的定理证明了许多分类器的性质。机器学习领域生机勃勃、严谨而且极其有用。然而，如果跟计算机视觉研究者交谈，则是另外一幅景象。他们会告诉你图像识别里“不可告人”的现实是：计算机视觉流程中真正重要的是数据和特征。也就是说，使用较干净的数据集和较有效的特征甚至比机器学习模型的选择对图像分类结果的影响更大。



5.6.1 学习特征表示

既然特征如此重要，它该如何表示呢？

我们已经提到，在相当长的时间里，特征都是基于各式各样手工设计的函数从数据中提取的。事实上，不少研究者通过提出新的特征提取函数不断改进图像分类结果。这一度为计算机视觉的发展做出了重要贡献。

然而，另一些研究者则持异议。他们认为特征本身也应该由学习得来。他们还相信，为了表征足够复杂的输入，特征本身应该分级表示。持这一想法的研究者相信，多层神经网络可能可以学得数据的多级表征，并逐级表示越来越抽象的概念或模式。以图像分类为例，并回忆5.1节（二维卷积层）中物体边缘检测的例子。在多层神经网络中，图像的第一级的表示可以是在特定的位置和角度是否出现边缘；而第二级的表示说不定能够将这些边缘组合出有趣的模式，如花纹；在第三级的表示中，也许上一级的花纹能进一步汇合成对应物体特定部位的模式。这样逐级表示下去，最终，模型能够较容易根据最后一级的表示完成分类任务。需要强调的是，输入的逐级表示由多层模型中的参数决定，而这些参数都是学出来的。

尽管一直有一群执着的研究者不断钻研，试图学习视觉数据的逐级表征，然而很长一段时间里这些野心都未能实现。这其中有诸多因素值得我们——分析。



5.6.1.1 缺失要素一：数据


包含许多特征的深度模型需要大量的有标签的数据才能表现得比其他经典方法更好。限于早期计算机有限的存储和90年代有限的研究预算，大部分研究只基于小的公开数据集。例如，不少研究论文基于加州大学欧文分校 (UCI) 提供的若干个公开数据集，其中许多数据集只有几百至几千张图像。这一状况在2010年前后兴起的大数据浪潮中得到改善。特别是，2009年诞生的ImageNet数据集包含了1,000大类物体，每类有多达数千张不同的图像。这一规模是当时其他公开数据集无法与之相提并论的。ImageNet数据集同时推动计算机视觉和机器学习研究进入新的阶段，使此前的传统方法不再具有优势。

5.6.1.2 缺失要素二：硬件

深度学习对计算资源要求很高。早期的硬件计算能力有限，这使训练较复杂的神经网络变得很困难。然而，通用GPU的到来改变了这一格局。很久以来，GPU都是为图像处理和计算机游戏设计的，尤其是针对大吞吐量的矩阵和向量乘法从而服务于基本的图形变换。值得庆幸的是，这其中的数学表达与深度网络中的卷积层的表达类似。通用GPU这个概念在2001年开始兴起，涌现出诸如OpenCL和CUDA之类的编程框架。这使得GPU也在2010年前后开始被机器学习社区使用。



AlexNet



2012年，AlexNet横空出世。这个模型的名字来源于论文第一作者的姓名Alex Krizhevsky [1]。AlexNet使用了8层卷积神经网络，并以很大的优势赢得了ImageNet 2012图像识别挑战赛。它首次证明了学习到的特征可以超越手工设计的特征，从而一举打破计算机视觉研究的前状。

[1] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In Advances in neural information processing systems (pp. 1097-1105).



AlexNet与LeNet的区别:

第一，与相对较小的LeNet相比，AlexNet包含8层变换，其中有5层卷积和2层全连接隐藏层，以及1个全连接输出层。下面我们来详细描述这些层的设计。

AlexNet第一层中的卷积窗口形状是 11×11 。因为ImageNet中绝大多数图像的高和宽均比MNIST图像的高和宽大10倍以上，ImageNet图像的物体占用更多的像素，所以需要更大的卷积窗口来捕获物体。第二层中的卷积窗口形状减小到 5×5 ，之后全采用 3×3 。此外，第一、第二和第五个卷积层之后都使用了窗口形状为 3×3 、步幅为2的最大池化层。而且，AlexNet使用的卷积通道数也大于LeNet中的卷积通道数数十倍。


紧接着最后一个卷积层的是两个输出个数为4096的全连接层。这两个巨大的全连接层带来将近1 GB的模型参数。由于早期显存的限制，最早的AlexNet使用双数据流的设计使一个GPU只需要处理一半模型。幸运的是，显存在过去几年得到了长足的发展，因此通常我们不再需要这样的特别设计了。

第二，AlexNet将sigmoid激活函数改成了更加简单的ReLU激活函数。一方面，ReLU激活函数的计算更简单，例如它并没有sigmoid激活函数中的求幂运算。另一方面，ReLU激活函数在不同的参数初始化方法下使模型更容易训练。这是由于当sigmoid激活函数输出极接近0或1时，这些区域的梯度几乎为0，从而造成反向传播无法继续更新部分模型参数；而ReLU激活函数在正区间的梯度恒为1。因此，若模型参数初始化不当，sigmoid函数可能在正区间得到几乎为0的梯度，从而令模型无法得到有效训练。

第三，AlexNet通过丢弃法（参见3.13节）来控制全连接层的模型复杂度。而LeNet并没有使用丢弃法。

第四，AlexNet引入了大量的图像增广，如翻转、裁剪和颜色变化，从而进一步扩大数据集来缓解过拟合。我们将在后面的9.1节（图像增广）详细介绍这种方法。

下面我们实现稍微简化过的AlexNet。



AlexNet(

(conv): Sequential(

(0): Conv2d(1, 96, kernel_size=(11, 11), stride=(4, 4)

(1): ReLU()

(2): MaxPool2d(kernel_size=3, stride=2, padding=0, dil

(3): Conv2d(96, 256, kernel_size=(5, 5), stride=(1, 1)

(4): ReLU()

(5): MaxPool2d(kernel_size=3, stride=2, padding=0, dil

(6): Conv2d(256, 384, kernel_size=(3, 3), stride=(1, 1

(7): ReLU()

(8): Conv2d(384, 384, kernel_size=(3, 3), stride=(1, 1

(9): ReLU()

(10): Conv2d(384, 256, kernel_size=(3, 3), stride=(1,

(11): ReLU()

(12): MaxPool2d(kernel_size=3, stride=2, padding=0, di

)

$$\lfloor (n_h - k_h + p_h + s_h) / s_h \rfloor \times \lfloor (n_w - k_w + p_w + s_w) / s_w \rfloor.$$

(fc): Sequential(

(0): Linear(in_features=6400, out_features=4096, bias=

(1): ReLU()

(2): Dropout(p=0.5)

(3): Linear(in_features=4096, out_features=4096, bias=

(4): ReLU()

(5): Dropout(p=0.5)

(6): Linear(in_features=4096, out_features=10, bias=Tr

)

)



合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY

AlexNet Pytorch实现:

```
class AlexNet(nn.Module):  
    def __init__(self):  
        super(AlexNet, self).__init__()  
        self.conv = nn.Sequential(  
            nn.Conv2d(1, 96, 11, 4), # in_channels, out_channels, kernel_size, stride, padding  
            nn.ReLU(),  
            nn.MaxPool2d(3, 2), # kernel_size, stride  
            # 减小卷积窗口, 使用填充为2来使得输入与输出的高和宽一致, 且增大输出通道数  
            nn.Conv2d(96, 256, 5, 1, 2),  
            nn.ReLU(),  
            nn.MaxPool2d(3, 2),  
            # 连续3个卷积层, 且使用更小的卷积窗口。除了最后的卷积层外, 进一步增大了输出通道数。  
            # 前两个卷积层后不使用池化层来减小输入的高和宽  
            nn.Conv2d(256, 384, 3, 1, 1),  
            nn.ReLU(),  
            nn.Conv2d(384, 384, 3, 1, 1),  
            nn.ReLU(),  
            nn.Conv2d(384, 256, 3, 1, 1),  
            nn.ReLU(),  
            nn.MaxPool2d(3, 2)  
        )
```



这里全连接层的输出个数比LeNet中的大数倍。使用丢弃层来缓解过拟合

```
self.fc = nn.Sequential(  
    nn.Linear(256*5*5, 4096),  
    nn.ReLU(),  
    nn.Dropout(0.5),  
    nn.Linear(4096, 4096),  
    nn.ReLU(),  
    nn.Dropout(0.5),  
    # 输出层。由于这里使用Fashion-MNIST，所以用类别数为10，而非论文中的1000  
    nn.Linear(4096, 10),  
)
```

```
def forward(self, img):  
    feature = self.conv(img)  
    output = self.fc(feature.view(img.shape[0], -1))  
    return output
```



VGG

AlexNet在LeNet的基础上增加了3个卷积层。但AlexNet作者对它们的卷积窗口、输出通道数和构造顺序均做了大量的调整。虽然AlexNet指明了深度卷积神经网络可以取得出色的结果，但并没有提供简单的规则以指导后来的研究者如何设计新的网络。

本节介绍VGG，它的名字来源于论文作者所在的实验室Visual Geometry Group [1]。VGG提出了可以通过重复使用简单的基础块来构建深度模型的思路。

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

<https://blog.csdn.net/yj771957559>

[1] Simonyan, K., & Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. arXiv preprint arXiv:1409.1556.



VGG特点:

对于给定的感受野（与输出有关的输入图片的局部大小），采用堆积的小卷积核优于采用大的卷积核，因为可以增加网络深度来保证学习更复杂的模式，而且代价还比较小（参数更少）。例如，在VGG中，使用了3个3x3卷积核来代替7x7卷积核，使用了2个3x3卷积核来代替5*5卷积核，这样做的主要目的是在保证具有相同感知野的条件下，提升了网络的深度，在一定程度上提升了神经网络的效果。

```
import time
import torch
from torch import nn, optim

import sys
sys.path.append("..")
import d2lzh_pytorch as d2l
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

def vgg_block(num_convs, in_channels, out_channels):
    blk = []
    for i in range(num_convs):
        if i == 0:
            blk.append(nn.Conv2d(in_channels, out_channels, kernel_size=3, padding=1))
        else:
            blk.append(nn.Conv2d(out_channels, out_channels, kernel_size=3, padding=1))
        blk.append(nn.ReLU())
    blk.append(nn.MaxPool2d(kernel_size=2, stride=2)) # 这里会使宽高减半
    return nn.Sequential(*blk)
```



下面构造一个高和宽均为224的单通道数据样本来观察每一层的输出形状。

```
net = vgg(conv_arch, fc_features, fc_hidden_units)
X = torch.rand(1, 1, 224, 224)

# named_children获取一级子模块及其名字(named_modules会返回所有子模块,包括子模块的子模块)
for name, blk in net.named_children():
    X = blk(X)
    print(name, 'output shape: ', X.shape)
```

输出:

```
vgg_block_1 output shape: torch.Size([1, 64, 112, 112])
vgg_block_2 output shape: torch.Size([1, 128, 56, 56])
vgg_block_3 output shape: torch.Size([1, 256, 28, 28])
vgg_block_4 output shape: torch.Size([1, 512, 14, 14])
vgg_block_5 output shape: torch.Size([1, 512, 7, 7])
fc output shape: torch.Size([1, 10])
```

可以看到，每次我们将输入的高和宽减半，直到最终高和宽变成7后传入全连接层。与此同时，输出通道数每次翻倍，直到变成512。因为每个卷积层的窗口大小一样，所以每层的模型参数尺寸和计算复杂度与输入高、输入宽、输入通道数和输出通道数的乘积成正比。VGG这种高和宽减半以及通道翻倍的设计使得多数卷积层都有相同的模型参数尺寸和计算复杂度。



VGG11

VGG-11通过5个可以重复使用的卷积块来构造网络。根据每块里卷积层个数和输出通道数的不同可以定义出不同的VGG模型

```
Sequential(  
  (vgg_block_1): Sequential(  
    (0): Conv2d(1, 8, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (1): ReLU()  
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
  )  
  (vgg_block_2): Sequential(  
    (0): Conv2d(8, 16, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (1): ReLU()  
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
  )  
  (vgg_block_3): Sequential(  
    (0): Conv2d(16, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (1): ReLU()  
    (2): Conv2d(32, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (3): ReLU()  
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
  )  
  (vgg_block_4): Sequential(  
    (0): Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (1): ReLU()  
    (2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (3): ReLU()  
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
  )  
  (vgg_block_5): Sequential(  
    (0): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (1): ReLU()  
    (2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (3): ReLU()  
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
  )  
)
```



批量归一化层

5.10.1.1 对全连接层做批量归一化

我们先考虑如何对全连接层做批量归一化。通常，我们将批量归一化层置于全连接层中的仿射变换和激活函数之间。设全连接层的输入为 $\mathbf{u}$ ，权重参数和偏差参数分别为 $\mathbf{W}$ 和 $\mathbf{b}$ ，激活函数为 ϕ 。设批量归一化的运算符为BN。那么，使用批量归一化的全连接层的输出为

$$\phi(\text{BN}(\mathbf{x})),$$

其中批量归一化输入 $\mathbf{x}$ 由仿射变换

$$\mathbf{x} = \mathbf{W}\mathbf{u} + \mathbf{b}$$

得到。考虑一个由 m 个样本组成的小批量，仿射变换的输出为一个新的小批量 $\mathcal{B} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(m)}\}$ 。它们正是批量归一化层的输入。对于小批量 $\mathcal{B}$ 中任意样本 $\mathbf{x}^{(i)} \in \mathbb{R}^d, 1 \leq i \leq m$ ，批量归一化层的输出同样是 d 维向量

$$\mathbf{y}^{(i)} = \text{BN}(\mathbf{x}^{(i)}),$$

并由以下几步求得。首先，对小批量 $\mathcal{B}$ 求均值和方差：

$$\begin{aligned}\boldsymbol{\mu}_{\mathcal{B}} &\leftarrow \frac{1}{m} \sum_{i=1}^m \mathbf{x}^{(i)}, \\ \boldsymbol{\sigma}_{\mathcal{B}}^2 &\leftarrow \frac{1}{m} \sum_{i=1}^m (\mathbf{x}^{(i)} - \boldsymbol{\mu}_{\mathcal{B}})^2,\end{aligned}$$

其中的平方计算是按元素求平方。接下来，使用按元素开方和按元素除法对 $\mathbf{x}^{(i)}$ 标准化：

$$\hat{\mathbf{x}}^{(i)} \leftarrow \frac{\mathbf{x}^{(i)} - \boldsymbol{\mu}_{\mathcal{B}}}{\sqrt{\boldsymbol{\sigma}_{\mathcal{B}}^2 + \epsilon}},$$

这里 $\epsilon > 0$ 是一个很小的常数，保证分母大于0。在上面标准化的基础上，批量归一化层引入了两个可以学习的模型参数，拉伸 (scale) 参数 $\boldsymbol{\gamma}$ 和偏移 (shift) 参数 $\boldsymbol{\beta}$ 。这两个参数和 $\mathbf{x}^{(i)}$ 形状相同，皆为 d 维向量。它们与 $\hat{\mathbf{x}}^{(i)}$ 分别做按元素乘法 (符号 $\odot$) 和加法计算：

$$\mathbf{y}^{(i)} \leftarrow \boldsymbol{\gamma} \odot \hat{\mathbf{x}}^{(i)} + \boldsymbol{\beta}.$$

至此，我们得到了 $\mathbf{x}^{(i)}$ 的批量归一化的输出 $\mathbf{y}^{(i)}$ 。值得注意的是，可学习的拉伸和偏移参数保留了不对 $\hat{\mathbf{x}}^{(i)}$ 做批量归一化的可能：此时只需学出 $\boldsymbol{\gamma} = \sqrt{\boldsymbol{\sigma}_{\mathcal{B}}^2 + \epsilon}$ 和 $\boldsymbol{\beta} = \boldsymbol{\mu}_{\mathcal{B}}$ 。我们可以对此这样理解：如果批量归一化无益，理论上，学出的模型可以不使用批量归一化。



5.10.1.2 对卷积层做批量归一化

对卷积层来说，批量归一化发生在卷积计算之后、应用激活函数之前。如果卷积计算输出多个通道，我们需要对这些通道的输出分别做批量归一化，且每个通道都拥有独立的拉伸和偏移参数，并均为标量。设小批量中有 m 个样本。在单个通道上，假设卷积计算输出的高和宽分别为 p 和 q 。我们需要对该通道中 $m \times p \times q$ 个元素同时做批量归一化。对这些元素做标准化计算时，我们使用相同的均值和方差，即该通道中 $m \times p \times q$ 个元素的均值和方差。



```
class BatchNorm(nn.Module):
    def __init__(self, num_features, num_dims):
        super(BatchNorm, self).__init__()
        if num_dims == 2:
            shape = (1, num_features)
        else:
            shape = (1, num_features, 1, 1)
        # 参与求梯度和迭代的拉伸和偏移参数，分别初始化成0和1
        self.gamma = nn.Parameter(torch.ones(shape))
        self.beta = nn.Parameter(torch.zeros(shape))
        # 不参与求梯度和迭代的变量，全在内存上初始化成0
        self.moving_mean = torch.zeros(shape)
        self.moving_var = torch.zeros(shape)

    def forward(self, X):
        # 如果X不在内存上，将moving_mean和moving_var复制到X所在显存上
        if self.moving_mean.device != X.device:
            self.moving_mean = self.moving_mean.to(X.device)
            self.moving_var = self.moving_var.to(X.device)
        # 保存更新过的moving_mean和moving_var，Module实例的training属性默认为true，调用.eval()后设成false
        Y, self.moving_mean, self.moving_var = batch_norm(self.training,
            X, self.gamma, self.beta, self.moving_mean,
            self.moving_var, eps=1e-5, momentum=0.9)
        return Y
```



```
net = nn.Sequential(  
    nn.Conv2d(1, 6, 5), # in_channels, out_channels, kernel_size  
    nn.BatchNorm2d(6),  
    nn.Sigmoid(),  
    nn.MaxPool2d(2, 2), # kernel_size, stride  
    nn.Conv2d(6, 16, 5),  
    nn.BatchNorm2d(16),  
    nn.Sigmoid(),  
    nn.MaxPool2d(2, 2),  
    d2l.FlattenLayer(),  
    nn.Linear(16*4*4, 120),  
    nn.BatchNorm1d(120),  
    nn.Sigmoid(),  
    nn.Linear(120, 84),  
    nn.BatchNorm1d(84),  
    nn.Sigmoid(),  
    nn.Linear(84, 10)  
)
```



残差网络 (ResNet)

Deep Residual Learning for Image Recognition

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun; Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770-778

Abstract

Deeper neural networks are more difficult to train. We present a residual learning framework to ease the training of networks that are substantially deeper than those used previously. We explicitly reformulate the layers as learning residual functions with reference to the layer inputs, instead of learning unreferenced functions. We provide comprehensive empirical evidence showing that these residual networks are easier to optimize, and can gain accuracy from considerably increased depth. On the ImageNet dataset we evaluate residual nets with a depth of up to 152 layers—8x deeper than VGG nets but still having lower complexity. An ensemble of these residual nets achieves 3.57% error on the ImageNet test set. This result won the 1st place on the ILSVRC 2015 classification task. We also present analysis on CIFAR-10 with 100 and 1000 layers. The depth of representations is of central importance for many visual recognition tasks. Solely due to our extremely deep representations, we obtain a 28% relative improvement on the COCO object detection dataset. Deep residual nets are foundations of our submissions to ILSVRC & COCO 2015 competitions, where we also won the 1st places on the tasks of ImageNet detection, ImageNet localization, COCO detection, and COCO segmentation.

Related Material

[\[pdf\]](#) [\[supp\]](#) [\[video\]](#) [\[bibtex\]](#)



何恺明2003年高中毕业于广州市执信中学，为当年广东省高考满分状元。2003-2007年就读于清华大学物理系基础科学班，本科毕业后进入香港中文大学攻读研究生，师从汤晓鸥。2009年成为CVPR最佳论文首位华人得主。2011年获得香港中文大学信息工程哲学博士学位，之后进入微软亚洲研究院工作。2016年8月加入Facebook AI Research（FAIR），担任研究科学家。2017年获得ICCV最佳论文奖（马尔奖）。2018年获得CVPR大会PAMI青年研究者奖。2022年入选AI 2000人工智能全球最具影响力学者榜单，综合排名第一。2023年获得未来科学大奖数学与计算机科学奖。2024年2月加入麻省理工学院电气工程与计算机科学系，担任副教授。何恺明的主要研究领域为计算机视觉和深度学习，是深度残差网络（ResNets）的主要开发者。




Kaiming He

Associate Professor, EECS, MIT
Verified email at mit.edu - [Homepage](#)
[Computer Vision](#) [Machine Learning](#)



Cited by	VIEW ALL	
	All	Since 2019
Citations	643471	578540
h-index	68	64
i10-index	76	75



Public access	VIEW ALL	
	0 articles	11 articles
not available		available
Based on funding mandates		

Co-authors		VIEW ALL
	Jian Sun Chief Scientist of Megvii, Manag...	>
	Shaoqing Ren NIO	>
	Ross Girshick Research Scientist, Allen Institut...	>
	Piotr Dollár FAIR	>



何恺明和导师汤晓鸥



合肥工业大学

HEFEI UNIVERSITY OF TECHNOLOGY





北京灰霾照片的去雾结果




He, Kaiming, Jian Sun, and Xiaoou Tang. "Single image haze removal using dark channel prior." 2009 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2009.



残差网络 (ResNet)







```
import time
import torch
from torch import nn, optim
import torch.nn.functional as F


import sys
sys.path.append("..")
import d2lzh_pytorch as d2l
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

class Residual(nn.Module): # 本类已保存在d2lzh_pytorch包中方便以后使用
    def __init__(self, in_channels, out_channels, use_1x1conv=False, stride=1):
        super(Residual, self).__init__()
        self.conv1 = nn.Conv2d(in_channels, out_channels, kernel_size=3, padding=1, stride=stride)
        self.conv2 = nn.Conv2d(out_channels, out_channels, kernel_size=3, padding=1)
        if use_1x1conv:
            self.conv3 = nn.Conv2d(in_channels, out_channels, kernel_size=1, stride=stride)
        else:
            self.conv3 = None
        self.bn1 = nn.BatchNorm2d(out_channels)
        self.bn2 = nn.BatchNorm2d(out_channels)

    def forward(self, X):
        Y = F.relu(self.bn1(self.conv1(X)))
        Y = self.bn2(self.conv2(Y))
        if self.conv3:
            X = self.conv3(X)
        return F.relu(Y + X)
```




为什么残差网络能训练更深的层？



由前四层
实现映射

由紫色层
实现残余映射



知乎 @Sakura



$$x_{l+1} = F(x_l) + x_l$$

$$\begin{aligned} x_{l+2} &= F(x_{l+1}) + x_{l+1} \\ &= F(x_{l+1}) + F(x_l) + x_l \end{aligned}$$

$$x_L = x_l + \sum_{i=l}^{L-1} F(x_i)$$



为什么残差网络能训练更深的层？



$$y = f(x) \quad \frac{\partial y}{\partial w} \quad w = w - \eta \frac{\partial y}{\partial w}$$

$$\begin{aligned} y' = g(f(x)) \quad \frac{\partial y'}{\partial w} &= \frac{\partial y'}{\partial y} \frac{\partial y}{\partial w} \\ &= \underbrace{\frac{\partial g(y)}{\partial y}}_{\text{Small}} \cdot \frac{\partial y}{\partial w} \end{aligned}$$

$$\begin{aligned} y'' = f(x) + g(f(x)) \quad \frac{\partial y''}{\partial w} &= \frac{\partial y}{\partial w} + \frac{\partial y'}{\partial w} \end{aligned}$$



Resnet到底在解决一个什么问题呢？

既然可以通过初试化和归一化（BN层）解决梯度弥散或爆炸的问题，那Resnet提出的那条通路是在解决什么问题呢？

在He的原文中有提到是解决深层网络的一种退化问题，但并未明确说明是什么问题！

已关注

写回答

邀请回答

好问题 120

4 条评论

分享

收起

The Shattered Gradients Problem: If resnets are the answer, then what is the question?

David Balduzzi, Marcus Frean, Lennox Leary, JP Lewis, Kurt Wan-Duo Ma, Brian McWilliams

A long-standing obstacle to progress in deep learning is the problem of vanishing and exploding gradients. Although, the problem has largely been overcome via carefully constructed initializations and batch normalization, architectures incorporating skip-connections such as highway and resnets perform much better than standard feedforward architectures despite well-chosen initialization and batch normalization. In this paper, we identify the shattered gradients problem. Specifically, we show that the correlation between gradients in standard feedforward networks decays exponentially with depth resulting in gradients that resemble white noise whereas, in contrast, the gradients in architectures with skip-connections are far more resistant to shattering, decaying sublinearly. Detailed empirical evidence is presented in support of the analysis, on both fully-connected networks and convnets. Finally, we present a new "looks linear" (LL) initialization that prevents shattering, with preliminary experiments showing the new initialization allows to train very deep networks without the addition of skip-connections.

Comments: ICML 2017, final version

Subjects: **Neural and Evolutionary Computing (cs.NE)**; Machine Learning (cs.LG); Machine Learning (stat.ML)

Cite as: [arXiv:1702.08591](https://arxiv.org/abs/1702.08591) [cs.NE]

(or [arXiv:1702.08591v2](https://arxiv.org/abs/1702.08591v2) [cs.NE] for this version)

<https://doi.org/10.48550/arXiv.1702.08591>

Journal reference: PMLR volume 70 (2017)

Submission history

From: David Balduzzi [[view email](#)]

[v1] Tue, 28 Feb 2017 01:06:13 UTC (1,304 KB)

[v2] Wed, 6 Jun 2018 10:08:21 UTC (1,321 KB)

<https://arxiv.org/abs/1702.08591>



Post-train Black-box Defense via Bayesian Boundary Correction

He Wang and Yunfeng Diao




图 1 (网络版彩图) 后训练贝叶斯能量对抗训练的框架示意图



稠密网络 (DenseNet)




图5.10 ResNet（左）与DenseNet（右）在跨层连接上的主要区别：使用相加和使用连结

Dense与**ResNet**的主要区别在于，DenseNet里模块B的输出不是像ResNet那样和模块A输出相加，而是在通道维上连结。这样模块A的输出可以直接传入模块B后面的层。在这个设计里，模块A直接跟模块B后面的所有层连接在了一起。这也是它被称为“稠密连接”的原因。



```
class DenseBlock(nn.Module):  
    def __init__(self, num_convs, in_channels, out_channels):  
        super(DenseBlock, self).__init__()  
        net = []  
        for i in range(num_convs):  
            in_c = in_channels + i * out_channels  
            net.append(conv_block(in_c, out_channels))  
        self.net = nn.ModuleList(net)  
        self.out_channels = in_channels + num_convs * out_channels # 计算输出通道数  
  
    def forward(self, X):  
        for blk in self.net:  
            Y = blk(X)  
            X = torch.cat((X, Y), dim=1) # 在通道维上将输入和输出连结  
        return X
```