



合肥工业大学


HEFEI UNIVERSITY OF TECHNOLOGY

针对图像分类的数据 隐私保护方法



不可学习样本 (Unlearnable Examples)



指那些通过常规的机器学习算法难以或无法有效学习的样本，通常具有噪声性与对抗性。





应用场景:

隐私保护: 在某些情况下, 生成不可学习样本可以用于保护用户隐私, 防止模型从数据中提取敏感信息。




假设用户A可以访问一个小的面部图像数据集, 使用数据集生成误差最小的噪声应用到自己的面部图像上。此后, 用社交媒体上的人脸图像训练基于DNN的人脸识别系统, 则该系统在用户A干净的人脸图像上表现不佳, 即DNN无法学习到用户A的人脸图像。可达到**隐私保护**的目的。



不可学习样本 (Unlearnable Examples)

指那些通过常规的机器学习算法难以或无法有效学习的样本，通常具有噪声性与对抗性。



如向训练数据添加误差最小化噪声（样本级），训练后模型测试精度接近随机猜测概率，即训练样本“不可学习”



不可学习样本通常具有以下特点：

- 1.噪声性：**样本中包含大量随机或无意义的噪声，使得模型难以从中提取有用的信息。
- 2.复杂性：**样本的特征空间非常复杂，难以用简单的模型或算法进行有效分类或回归。
- 3.稀疏性：**样本的特征非常稀疏，即大部分特征值为零或缺失，导致模型难以捕捉到有效的模式。
- 4.对抗性：**样本可能是人为设计的，目的是欺骗模型，使其做出错误的预测。



数据不可学习的定义:

3.1.1 Data Protector. Suppose that the data protectors have access to the original dataset and it is denoted as $\mathcal{D}_c = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^N$ with N clean samples, in which i.i.d. input-label pairs $(\mathbf{x}^{(i)}, y^{(i)})$ are drawn from the joint data distribution $p_d(\mathbf{x}, y)$. The protectors' goal is to protect the data from unauthorized training after its release. To this end, they release an unlearnable dataset $\mathcal{D}_u = \{(\tilde{\mathbf{x}}^{(i)}, y^{(i)})\}_{i=1}^N$ to the unauthorized users. The protector aims to make a classifier $f_\theta : \mathcal{X} \rightarrow \mathcal{Y}$ trained on the unlearnable dataset perform poorly on the original clean data distribution $p_d(\mathbf{x}, y)$:

$$\begin{aligned} \theta^* &= \arg \min_{\theta} \mathbb{E}_{(\tilde{\mathbf{x}}, y) \in \mathcal{D}_u} [\mathcal{L}(f_\theta(\tilde{\mathbf{x}}), y)] \\ &\text{s.t. } p_{\theta^*}(y|\mathbf{x}) \neq p_d(y|\mathbf{x}) \end{aligned} \quad (1)$$

where $\mathcal{L}(\cdot)$ is the cross-entropy loss. Since unlearnable perturbations should not affect the normal data utility, it is assumed that $\tilde{\mathbf{x}} = \mathbf{x} + \delta$, where δ is the “invisible” unlearnable perturbations bounded by $\|\delta\|_p \leq \varepsilon$.

Jiang, Wan, Yunfeng Diao, He Wang, Jianxin Sun, Meng Wang, and Richang Hong. "Unlearnable examples give a false sense of security: Piercing through unexploitable data with learnable examples." In Proceedings of the 31st ACM International Conference on Multimedia, pp. 8910-8921. 2023.



3.2 GENERATING ERROR-MINIMIZING NOISE

Ideally, the noise should be generated on an additional dataset that is different from $\mathcal{D}_c$. This will involve a class-matching process to find the most appropriate class from the additional dataset for each class to protect in $\mathcal{D}_c$. For simplicity, here we define the noise generation process on $\mathcal{D}_c$ and will verify the effectiveness of using an additional dataset in the experiments. Given a clean example $\mathbf{x}$, we propose to generate the error-minimizing noise δ for training input $\mathbf{x}$ by solving the following bi-level optimization problem:

$$\arg \min_{\theta} \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}_c} \left[\min_{\delta} \mathcal{L}(f'(\mathbf{x} + \delta), y) \right] \quad \text{s.t.} \quad \|\delta\|_p \leq \epsilon \quad (2)$$

Sample-wise Generation. We adopt the first-order optimization method PGD (Madry et al., 2018) to solve the constrained inner minimization problem as follows:

$$\mathbf{x}'_{t+1} = \Pi_{\epsilon}(\mathbf{x}'_t - \alpha \cdot \text{sign}(\nabla_{\mathbf{x}} \mathcal{L}(f'(\mathbf{x}'_t), y))) \quad (3)$$



不可学习样本实现方法:

➤ 噪声注入:

- ①方法: 在原始数据中随机注入噪声, 使得样本变得不可学习。
- ②实现: 可以使用随机数生成器在数据中添加高斯噪声或其他类型的随机噪声。

➤ 特征稀疏化:

- ①方法: 通过随机删除或置零部分特征, 使得样本变得稀疏。
- ②实现: 可以使用随机掩码 (mask) 来选择性地删除特征。

➤ 对抗性样本生成:

- ①方法: 通过微小扰动原始数据, 生成对抗性样本, 使得模型难以正确分类。
- ②实现: 可以使用梯度上升法或其他优化方法来生成对抗性样本。



数据隐私保护机制有可能被消除吗？

3.2 Learnable Examples

Existing countering methods rely on specific training schemes. However, we argue that an ultimate threat against UEs should turn unexploitable data $\mathcal{D}_u$ into a learnable dataset $\mathcal{D}_l$. $\mathcal{D}_l$ can be used normally as the original clean training data, enabling further unauthorized exploitation such as standard straining and representation learning. Here we consider standard setting in supervised learning as an example, a model trained on $\mathcal{D}_l$ can easily generalize well on the original clean data distribution $p_d(\mathbf{x}, y)$:

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{(\mathbf{x}, y) \in \mathcal{D}_l} [\mathcal{L}(f_{\theta}(\mathbf{x}), y)] \quad (4)$$

$$\text{s.t. } \mathcal{D}_l = \text{denoise}(\mathcal{D}_u); p_{\theta^*}(y|\mathbf{x}) = p_d(y|\mathbf{x})$$



Joint-conditional Diffusion Purification






Figure 2: Visual results of LEs with distribution mismatch. UEs are drawn from the protected (unlearnable) CIFAR-10 dataset. LEs(S1) and LEs(S3) choose the surrogate distribution CIFAR-100 and SVHN respectively.




Figure 3: Visual examples of Joint-conditional Diffusion Purification(JCDP) vs. Unconditional Diffusion Purification(UCDP) on CIFAR-100.



深度伪造人脸鉴别算法

目录

- 1 研究背景介绍
- 2 深度伪造人脸检测与定位
- 3 多模态伪造检测与定位
- 4 未来展望




研究背景介绍

研究背景

近年以来，以图像生成式大模型为代表人工智能技术发展迅速，产生了丰富多彩的应用场景。


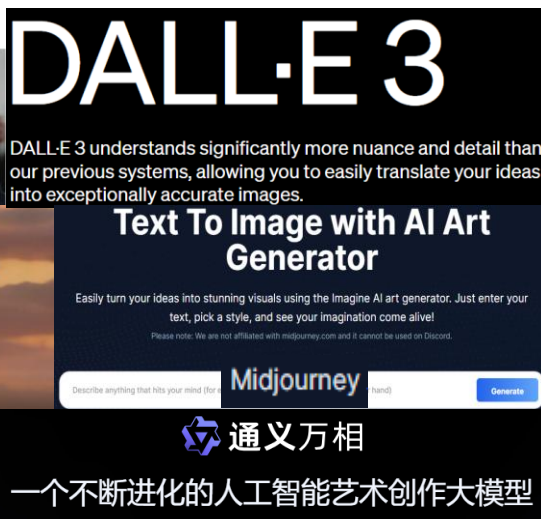
然而，技术的普及，自然会被恶意利用，对网络安全和社会稳定造成一定程度的影响，其中以深度伪造人脸技术危害尤为明显。



Stable Diffusion XL

Create and inspire using the world's fastest-growing open source AI platform

With Stable Diffusion XL, you can create descriptive images with shorter prompts and generate words within images. The model is a significant advancement in image generation capabilities, offering enhanced image composition and face generation that results in stunning visuals and realistic aesthetics.



研究背景

➤ 深度伪造人脸

Deepfake（深度伪造）一词由“deep learning”（深度学习）和“fake”（伪造）组合而成，主要包含以下内容：

1. 人脸替换：将人像覆盖至既有图片或视频上，实现面部合成以假乱真。
2. 人脸重演：操纵视频中人像的面部特征，扭曲一个人的表情，包括口型、眉毛、眼睛的运动和头部的倾斜。
3. 人脸生成：基于训练数据生成全新的人脸图像。

➤ 相关的法律法规

- ✓ 《中华人民共和国刑法》
- ✓ 《中华人民共和国民法典》
- ✓ 《中华人民共和国网络安全法》
- ✓ 《中华人民共和国个人信息保护法》
- ✓ 《中华人民共和国网络信息内容生态治理规定》
- ✓ 《互联网信息服务深度合成管理规定》
- ✓ 《生成式人工智能服务管理办法（试行）》




研究背景

➤ 跨数据集场景下的深度伪造人脸

- 深度伪造生成工具大规模普及，简单易用
- 伪造内容多种多样，制作者的目的不可控
- 传播平台与流通途径变化莫测

- ✓ 未知的伪造技术类型
- ✓ 未知的原始源数据
- ✓ 未知的干扰噪声

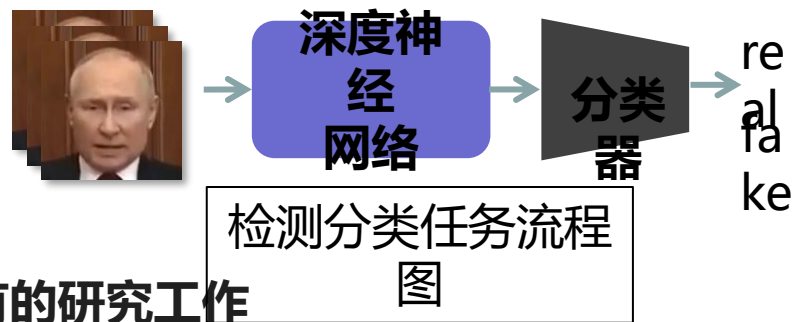



学术数据集

- FaceForensics++
- Celeb-DF
- DFDC
- ForgeryNet
- FFIW
- OpenForensics


研究背景

➤ 鉴别跨数据集场景下的深度伪造人脸



已有的研究工作

- 在跨数据集场景下的泛化检测效果较差
- 忽略深度伪造



研究目标

- 提升检测模型在跨数据集场景下的泛化能力
- 在跨数据集场景下构建篡改区域定位任务和提升泛化性能



深度伪造人脸检测与定位

基于区域感知和身份无关特征的伪造人脸检测算法


➤ 研究动机

现有方法的问题：


- 现有方法大多数是利用空间域的特征，即直接处理RGB图像或特征图；
- 空间域的特征多样，现有模型容易被伪造无关的特征干扰 影响模型



利用Grad-CAM发现基础模型倾向于关注非伪造的背景区域



利用t-SNE发现基础模型根据人脸身份语义信息判断真假



Training Set	Testing Set	Image-level ACC
<i>train</i>	<i>bg2</i>	95.09
<i>train + bg1</i>	<i>bg2</i>	88.74
<i>train</i>	<i>id2</i>	84.81
<i>train + id1</i>	<i>id2</i>	79.06

设计特殊实验，进一步验证了非伪造背景区域和人脸身份语义信息对基础模型泛化性能的影响


解决方案：

- ✓ 探究空间域无关特征对伪造人脸检测模型泛化能力的影响；
- ✓ 提出针对性的特征学习模块，消除无关特征干扰。

基于区域感知和身份无关特征的伪造人脸检测算法

➤ 技术细节

- ✓ 提出了**伪造区域引导的自注意力模块 (FR)**，以减少非伪造背景区域的影响，并使模型专注于伪造区域来做出决策；
- ✓ 提出了**一个人脸关键点引导的特征丢弃模块 (LM)**，通过随机删除人脸结构化信息区域的特征来破坏身份特征，避免模型受到人脸身份特征的干扰；
- ✓ 提出了一种**联合学习框架**，对于现有的分类基础模型，在端到端的联合训练时随机使用这两个互补模块，在测试时舍弃；无需改变基础模型网络结构，“即插即用”地使用提出的两个互补模块。



- Forgery Region Guided Self-attention Module 伪造区域引导的自注意力模块 (FR)；
- Landmark Guided Dropout Module 人脸关键点引导的特征丢弃模块 (LM)；
- Randomly Selection 随机选择机制。

基于区域感知和身份无关特征的伪造人脸检测算法

➤ 实验结果


在 FF++ 数据集上比较实验结果

Methods	C40		C23		RAW	
	ACC	AUC	ACC	AUC	ACC	AUC
Steg.Features ^[26]	55.98	—	70.97	—	97.63	—
LD-CNN ^[33]	58.69	—	78.45	—	98.57	—
Constrained Conv ^[32]	66.84	—	82.97	—	98.74	—
MesoNet ^[43]	70.47	—	83.10	—	95.23	—
Face X-ray ^[70]	—	61.60	—	97.40	—	98.50
Xception-ELA ^[89]	79.63	82.90	93.86	94.80	98.57	98.40
Xception ^[13]	86.86	89.30	95.73	96.30	99.26	99.20
F ³ -Net ^[62]	90.43	93.30	97.52	98.10	99.95	99.80
FRLM(ours)	90.71	93.69	97.63	99.50	99.98	99.99

在跨数据集上比较实验结果

Methods	Training Set	CDF-1	CDF-2	DFD	DFDC
		AUC			
Two-stream ^[39]	Private Data	55.70	53.80	52.80	61.40
MesoNet ^[43]		53.60	54.80	76.00	75.30
FWA ^[69]		53.80	56.90	74.30	72.70
FFD ^[48]		71.20	—	—	—
FakeSpotter ^[51]		—	66.80	—	—
Face X-ray ^[70]	FF++	80.58	—	95.40	80.90
Multi-task ^[45]		36.50	54.30	54.10	53.60
Capsule ^[82]		—	57.50	64.00	53.30
SMIL ^[55]		—	56.30	—	—
F ³ -Net ^[62]		—	65.20	—	—
Xception ^[13]		38.70	65.50	63.23	64.78
FRLM(ours)		76.52	70.58	68.17	69.81

(a)-(e)表示不同模块的 Grad-CAM 可视化



- 定量的实验结果表明提出的方案在跨数据集场景下泛化结果最优
- 定性的可视化结果展现出本方案可以学习到伪造区域特征，并在跨数据集场景下保持了这种能力

基于分层级频率信息的伪造人脸检测方法


➤ 研究动机

现有方法的问题：

- 当伪造人脸的视觉质量下降(如噪声、图像或视频压缩和模糊)时，空间伪影可能被破坏，显示出明显的脆弱性；
- 此外，以往的基于频率信息的方法大多在输入端 RGB image或者浅层 feature map提取频率特征，没有研究工作关注多层级特征上的频率信息。

解决方案：

- ✓ 构建Transformer-CNN结合的双分支的网络结构；
- ✓ 基于频率注意力的多层级中高频信息提取方法。




(a)和(b)是伪造图像，(c)是真实图像，可以观察到真假图像在RGB、feature map和低频上几乎一样，在中高频信息差异较大

基于分层级频率信息的伪造人脸检测方法

➤ 技术细节

- ✓ 提出了一种**双分支网络**用于深度人脸伪造检测；
- ✓ 提出了一种新的**基于频率的特征细化(FFR)模块**来提取RGB特征上的中高频伪造痕迹，充分利用了更具泛化和鲁棒的频域特征，并避免了空间伪像的脆弱性；
- ✓ 提出了一个**共享的和频率辅助的全局-局部交互(GLI)模块**，该模块被分层地放置于双分支网络的多个阶段中，以进行全局信息和局部特征

Miao C, Tan Z, Chu Q, et al. Hierarchical frequency-assisted interactive networks for face manipulation detection[J]. IEEE Transactions on Information Forensics and Security, 2022, 17: 3008-3021.



(a) HFI-Net

- Patch Embedding: 将RGB图像映射拆分成一系列的一维tokens;
- Trans. Block: ViT 中使用的transformer模块;
- GLI Module: 由两个FFR模块组成;
- Bottleneck: 将一维tokens转换成卷积网络中的二维feature map;
- Seperable Conv: Xception 中的深度可分离卷积。



基于分层级频率信息的伪造人脸检测方法

实验结果

在 FF++ 数据集上比较实验结果

Type	Methods	Ref.	Additional Supervision	Additional Loss Function	C40		C23	
					AUC	Acc.	AUC	Acc.
Image-level	Steg. Features [44]	TIFS 2012	No	No	55.98	—	70.97	—
	Cozzolino et al. [47]	IH&MMSec 2017	No	No	58.69	—	78.45	—
	Bayar & Stamm [73]	IH&MMSec 2016	No	No	66.84	—	82.97	—
	Rahmouni et al. [74]	WIFS 2017	No	No	70.47	—	83.10	—
	MseoNet [9]	WIFS 2018	No	No	—	70.47	—	83.10
	Xception [3]	ICCV 2019	No	No	81.76	80.32	94.86	92.39
	SPSL [42]	CVPR 2021	No	No	82.82	81.57	95.32	91.50
	M2TR [30]	arXiv 2021	No	No	87.15	83.89	96.75	91.86
	HFI-Net (ours)	—	No	No	88.40	85.69	97.07	91.87
	HFI-Net (ours) ↑	—	No	No	90.75	86.90	98.66	95.12
Image-based Video-level	FRLM [33]	TBIOM 2021	Yes	Yes	93.69	90.71	99.50	97.63
	Local-Relation [43]	AAAI 2021	Yes	Yes	95.21	91.47	99.46	97.59
	M2TR [30]	Arxiv 2021	Yes	Yes	94.22	92.35	99.48	98.23
	MaDD [15]	CVPR 2021	No	Yes	87.26	86.95	98.97	96.37
	Two-branch [41]	ECCV 2021	No	Yes	91.10	86.34	99.10	96.43
	FDFL [36]	CVPR 2021	No	Yes	92.40	89.00	99.30	96.69
	Xception [3]	ICCV 2019	No	No	89.30	86.86	94.80	93.86
	F ³ -Net [40]	ECCV 2020	No	No	93.30	90.43	98.10	97.52
	M2TR [30]	arXiv 2021	No	No	91.82	87.14	98.43	94.71
	MTD-Net [34]	TIFS 2021	No	No	—	—	99.38	—
	HFI-Net (ours)	—	No	No	92.23	88.86	98.86	94.43
	HFI-Net (ours) ↑	—	No	No	94.19	91.00	99.58	97.71

在跨伪造方法的比较实验结果

Methods	GID-DF		GID-FF	
	AUC	Acc.	AUC	Acc.
EfficientNet [76]	75.30	67.60	67.40	61.41
ForensicTransfer [77]	—	68.20	—	55.00
Multi-task [11]	—	66.76	—	56.50
MLDG [78]	73.12	67.15	61.70	58.12
LTW [67]	75.60	69.15	72.40	65.70
HFI-Net (ours)	86.80	78.57	73.01	65.00

定量的实验结果表明提出的方案在跨数据集场景下泛化结果最优

- 在真实世界数据干扰下表现最好的鲁棒性

在跨数据集上比较实验结果

Methods	Ref.	Training set	Unseen testing set					
			Celeb-DF (V2)	Celeb-DF (V1)	TIMIT (HQ)	TIMIT (LQ)	DFDC	UADFV
Multi-task [11] *	arXiv 2019	FF++	54.30	36.50	55.30	62.20	53.60	65.80
Capsule [12] *	ICASSP 2019	FF++	57.50	—	74.40	78.40	53.30	61.30
Local-Relation [43] *	AAAI 2021	FF++	—	78.26	—	—	76.53	—
FFD [14] #	CVPR 2020	DFFD	—	64.40	—	—	—	—
PCL [23] #	ICCV 2021	FF++&I2G	81.80	—	—	—	—	—
SMIL [18]	MM 2020	FF++ (C40)	56.30	—	—	—	—	—
F ³ -Net [40]	ECCV 2020	FF++ (C40)	65.17	—	—	—	—	—
Xception [3]	ICCV 2019	FF++ (C40)	65.50	—	70.50	75.80	69.70	48.06
FRLM [33]	TBIOM 2021	FF++ (C40)	70.58	76.52	65.48	70.68	69.81	64.20
Two-branch [41]	ECCV 2020	FF++ (C40)	73.41	—	—	—	—	—
SPSL [42]	CVPR 2021	FF++ (C40)	76.88	—	—	—	—	—
HFI-Net (ours)	—	FF++ (C40)	82.37	76.73	86.81	86.01	77.91	84.59
Xception [3]	ICCV 2019	FF++ (C23)	65.30	—	94.40	95.90	72.20	68.67
MT2R [30]	arXiv 2021	FF++ (C23)	65.17	—	—	—	—	—
MaDD [15]	CVPR 2021	FF++ (C23)	67.44	—	—	—	—	—
MTD-Net [34]	TIFS 2021	FF++ (C23)	70.12	—	—	—	—	—
Face X-ray [22]	CVPR 2020	FF++ (C23)	—	74.20	—	—	70.00	—
GEED [35]	CVPR 2021	FF++ (C23)	—	79.40	—	—	79.70	—
HFI-Net (ours)	—	FF++ (C23)	83.28	83.53	97.31	99.58	73.65	83.42

在真实世界干扰数据上的比较实验

Methods	std		
	std/rand	std/sing	std/mix3
C3D [79]	92.38	87.63	—
TSN [80]	95.00	91.50	—
I3D [81]	96.88	90.75	—
ResNet+LSTM [68]	97.13	90.63	—
F ³ -Net [40]	92.79	86.82	79.10
Xception [3]	94.75	88.38	82.32
M2TR [30]	94.78	91.79	86.32
MTD-Net [34]	95.22	—	86.89
HFI-Net (ours)	97.26	93.04	90.55

基于高频细粒度注意力网络的伪造人脸检测算法


➤ 研究动机

现有方法的问题：

- 基于Transformer的深度伪造人脸检测方法，大多是以Transformer为主干网络结合部分CNN层，或Transformer和CNN组成双分支网络结构，或以CNN为主干网络结合部分transformer模块；
- 同时，大多数Transformer网络结构，如ViT，缺少对局部特征的描述能力；经过改进的结合了CNN优势的Transformer网络结构，如Swin，均是针对通用任务设计，没有专门为深度伪造任务设计；
- 已有的基于频率的研究工作针对

解决方案：

- ✓ 提出了细粒度的注意力机制；
- ✓ 提出了高频采样器；
- ✓ 组成具有高频细粒度特征提取能力的Transformer网络结构。



Real表示真实图像，NT和FF表示伪造图像，LL，LH，HL和HH表示从低到高的四个频段，在高频HH部分真假图像之间差异最大

基于高频细粒度注意力网络的伪造人脸检测算法

➤ 技术细节


✓ 提出了一个统一的端到端框架，称为**高频细粒度 Transformer (F2Trans) 网络**，适用于伪造人脸检测任务；

✓ 提出了一种新颖的**中心差分注意力方法 (CDA)**，拥有捕捉内在细节和细粒度模式的能力，它适用于局部的伪造人脸篡改线索检测；

✓ 提出了一种**高频小波采样器 (HWS)**，在保留高

Miao, C., Tan, Z., Chu, Q., et al. F2Trans: High-Frequency Fine-Grained Transformer for Face Forgery Detection[J]. IEEE Transactions on Information Forensics and Security (TIFS), 2023, 18: 1039-1051.

频分量的同时丢弃低频信息，这有助于同时在空间和频率域中提取更泛化的伪造痕迹。



- CDAT: 由CDA 和 LN, MLP组成的Transformer模块
- HWS: 高频小波采样器
- LSC: 局部跳跃连接策略
- Stem: 将输入的 RGB 图像映射到不重叠的tokens
- Stem 和 LSC 的结构由空间深度卷积和线性层组成



基于高频细粒度注意力网络的伪造人脸检测算法

➤ 实验结果

视频级 intra-dataset 评价实验结果

Methods	Ref.	FF++(C40)		FF++(C23)	
		AUC	ACC	AUC	ACC
IAW ^[64]	TBIOM 2021	92.97	88.96	99.60	96.75
Local-Relation ^[73]	AAAI 2021	95.21	91.47	99.46	97.59
MADD ^[53]	CVPR 2021	87.26	86.95	98.97	96.37
FDFL ^[63]	CVPR 2021	92.40	89.00	99.30	96.69
Two-branch ^[76]	ECCV 2020	91.10	86.34	99.10	96.43
DIANet ^[58]	IJCAI 2021	94.50	89.77	98.80	96.37
Add-Net ^[128]	MM 2020	91.01	87.50	97.74	96.78
DCL ^[77]	AAAI 2022	–	–	99.30	–
MTD-Net ^[112]	TIFS 2021	–	–	99.38	–
F ³ -Net ^[62]	ECCV 2020	93.30	90.43	98.10	97.52
PEL ^[65]	AAAI 2022	94.28	90.52	99.32	97.63
F²Trans-S	–	94.11	90.14	99.73	98.14
F²Trans-B	–	94.04	90.57	99.74	98.71

• 提出的方案在跨数据集场景下泛化结果最优

• 测试场景包含：
(1)未知的伪造技术类型
(2)未知的原始源数据
(3)未知的干扰噪声

视频级 cross-manipulation 泛化性实验结果

Methods	GID-DF (C23)		GID-DF (C40)		GID-FF (C23)		GID-FF (C40)	
	AUC	ACC	AUC	ACC	AUC	ACC	AUC	ACC
EfficientNet ^[132]	91.11	82.40	75.30	67.60	80.1	63.32	67.40	61.41
Focalloss ^[68]	90.31	81.33	74.95	67.47	79.80	60.80	67.21	61.00
ForensicTransfer ^[66]	–	72.01	–	68.20	–	64.50	–	55.00
Multi-task ^[45]	–	70.30	–	66.76	–	58.74	–	56.50
MLDG ^[133]	91.82	84.21	73.12	67.15	77.10	63.46	61.70	58.12
LTW ^[68]	92.70	85.60	75.60	69.15	80.20	65.60	72.40	65.70
DCL ^[77]	94.90	87.70	83.82	75.90	82.93	68.40	75.07	67.85
F²Trans-S	97.47	89.64	86.92	77.86	90.55	81.43	76.52	66.79
F²Trans-B	98.92	92.86	88.77	82.14	94.08	86.07	77.73	70.36

视频级 cross-dataset 泛化性实验结果 (AUC)

Methods	Ref.	Training Set	Unseen Testing Set	
			CDF-2	DFDC
FWA ^[69]	CVPRW 2019	Others	69.50	67.30
Multi-task ^[45]	BTAS 2019		75.70	68.10
PCL ^[71]	ICCV 2021		90.03	74.37
Two-branch ^[76]	ECCV 2020	FF++ (C40)	76.70	–
PatchForensics ^[130]	ECCV 2020	FF++ (C23)	69.60	65.60
CNN-GRU ^[61]	CVPR 2020		69.80	68.90
DIANet ^[58]	IJCAI 2021		70.40	–
F ³ -Net ^[62]	ECCV 2020		71.21	72.88
Xception ^[113]	ICCV 2019		73.70	70.90
GFF ^[74]	CVPR 2021		75.31	71.58
STIL ^[59]	MM 2020		75.58	–
MADD ^[53]	CVPR 2021		76.65	67.34
LTW ^[68]	AAAI 2021		77.14	74.58
Local-Relation ^[73]	AAAI 2021		78.26	76.53
Face X-ray ^[70]	CVPR 2020		79.50	65.50
DCL ^[77]	AAAI 2022		82.30	76.71
LipForensics ^[131]	CVPR 2021		82.40	73.50
FTCN ^[107]	ICCV 2021		86.90	74.00
F²Trans-S	–	FF++ (C40)	80.98	76.26
F²Trans-B	–	–	83.96	74.20
F²Trans-S	–	FF++ (C23)	87.46	77.69
F²Trans-B	–	–	89.87	76.15

视频级 real-world perturbations 鲁棒性实验结果 (ACC)

Methods	std (training set)		
	std/sing	std/rand	std/mix3
C3D ^[134]	87.63	92.38	–
TSN ^[135]	91.50	95.00	–
I3D ^[136]	90.75	96.88	–
ResNet+LSTM ^[21]	90.63	97.13	–
Xception ^[113]	88.38	94.75	82.32
MTD-Net ^[112]	–	95.22	86.89
F²Trans-S	95.27	96.27	91.79
F²Trans-B	95.52	97.76	92.54

基于多频谱类别中心的伪造人脸检测定位算法


➤ 研究动机

现有方法的问题：

- 以往深度伪造人脸鉴别方法仅仅利用篡改区域掩码提供辅助监督信息，主要目的是提升检测分类性能，而不是定位；
- 目前篡改定位的任务流程不够清晰、数据集篡改区域标注不够完善、没有统一性能基准以及评价指标；
- 已有的定位相关方法往往忽略了在定位网络抑制语义不可知的特征。

解决方案

- ✓ 尝试优化改善现有数据集的篡改区域标注；
- ✓ 构建深度伪造人脸篡改区域定位的性能基准；
- ✓ 提出了一种新颖的多频谱类中心网络 (MSCCNet) 用于人脸篡改检测和定位。



MG1和MG2表示以前的标注处理方法，存在碎片化和不连续的问题

基于多频谱类别中心的伪造人脸检测定位算法

➤ 技术细节


- ✓ 通过引入更多合理的**像素级注释**重构了 FaceForensics++ (FF++) 数据集。然后，基于注释的 FF++ 数据集进行了全面的伪造人脸**篡改区域定位基准测试**；

- ✓ 设计了一种新颖的**多光谱类中心网络 (MSCCNet)**；




Types	Train Set	Valid Set	Test Set	All Sets
DF [14]	28,756	5,560	5,560	39,876
FF [60]	28,724	5,522	5,560	39,806
FS [18]	28,760	5,560	5,560	39,880
FSH [33]	28,760	5,560	5,560	39,880
NT [59]	28,724	5,522	5,560	39,806
All Types	143,724	16,922*	16,929*	177,575

非多数据集重构后的数据组成

(MSCC) 模块，用于学习更具泛化能力和语义无关性的特征。



本方案提出的像素级注释流程



Miao C, Chu Q, Tan Z, et al. Multi-spectral Class Center Network for Face Manipulation Detection and Localization. 已投稿

基于多频谱类别中心的伪造人脸检测定位算法

实验结果

数据集分布内评估结果

Methods	References	C40				C23			
		Image-level		Pixel-level		Image-level		Pixel-level	
		ACC	AUC	F1	mIoU	ACC	AUC	F1	mIoU
HPFCN [32]	ICCV 2019	82.05	69.08	60.53	48.37	86.60	88.69	69.12	55.91
Muilt-task [46]	BTAS 2019	71.09	74.05	74.91	61.86	88.08	93.41	81.88	70.39
FFD [13]	CVPR 2020	81.65	80.05	61.24	48.84	90.94	94.54	72.63	59.27
M2TR [62]	ICMR 2022	86.18	86.34	75.33	62.02	93.44	97.18	85.13	74.78
SLADD [7]	CVPR 2022	86.25	85.53	70.95	57.86	91.12	97.23	79.96	67.87
MVSS [11]	TPAMI 2022	85.08	81.99	82.34	70.82	95.30	98.71	88.79	80.20
CAT-Net [31]	IJCV 2022	85.86	85.77	84.89	74.40	96.14	98.83	89.18	80.86
HiFi-Net [23]	CVPR 2023	72.77	80.28	76.66	63.17	89.46	97.35	84.81	74.28
MSCCNet (ours)	-	88.07	87.61	86.82	77.22	97.21	98.94	90.71	83.29


跨数据集评估结果

Methods	Image-level		Pixel-level	
	ACC	AUC	F1	mIoU
HPFCN [32]	60.35	48.20	59.74	47.87
Muilt-task [46]	5.82*	52.36	42.34	36.59
FFD [13]	17.54	62.03	43.68	37.31
M2TR [62]	75.82	53.16	69.90	56.93
SLADD [7]	99.36*	47.79	64.93	52.46
MVSS [11]	99.49*	50.23	59.48	42.37
CAT-Net [31]	61.90	46.45	74.07	61.04
HiFi-Net [23]	70.81	54.26	76.38	62.34
MSCCNet (ours)	85.55	64.18	77.96	65.26

- 提出的方案在跨数据集场景下定位性能的泛化结果最优
- 可视化结果表明提出的方案可以较准确的预测局部篡改区域


未见过的篡改类型评估结果

Methods	Deepfakes		Face2Face		FaceSwap		FaceShifter		NeuralTextures		Average	
	F1	mIoU	F1	mIoU	F1	mIoU	F1	mIoU	F1	mIoU	F1	mIoU
HPFCN [32]	66.09	55.78	56.79	47.06	63.47	53.69	57.16	46.61	53.31	44.54	59.53	49.54
Multi-task [46]	72.74	61.17	60.77	50.04	57.25	48.54	58.21	47.75	53.42	44.88	60.48	50.48
FFD [13]	67.77	56.54	46.24	41.06	53.24	47.50	61.31	49.69	54.50	45.13	56.61	47.98
M2TR [62]	73.15	60.83	62.73	51.17	64.21	52.89	54.02	44.91	57.58	47.11	62.34	51.38
SLADD [7]	74.79	63.58	59.91	49.31	63.08	53.71	58.82	48.11	55.80	46.12	62.48	52.17
MVSS [11]	70.61	58.11	62.07	50.71	63.52	53.03	62.55	49.75	55.36	45.61	62.82	51.44
CAT-Net [31]	71.13	58.32	63.92	51.51	64.55	53.07	63.76	51.40	56.89	47.19	64.05	52.30
HiFi-Net [23]	52.41	44.94	61.35	50.15	60.74	49.83	52.64	44.12	55.26	45.97	56.48	47.00
MSCCNet (ours)	75.28	63.20	64.23	52.21	65.15	54.03	63.81	51.58	57.79	47.37	65.25	53.68



基于对抗学习策略的可泛化伪造检测算法


- 设计动机：现有方法通常将人脸伪造检测视为一个二分类问题，但是观察到其提取的判别特征并不是本质的，与样本的伪造方式以及身份信息相关，进而影响伪造检测的性能。
- 核心技巧：基于生成对抗网络 GAN 的训练思想，旨在通过两个神经网络的对抗和合作，使得生成器和判别器在训练过程中学习本质的伪造判别特征。
- 核心思路：基于深度神经网络 Xception 构建二分类器，在其基础上设计两个对抗学习模块：
1) 针对伪造方法做对抗学习，目的是使特征生成器无法区分不同的伪造方法；
2) 针对人脸身份做对抗学习，目的是使特征生成器无法区分不同的人脸身份。



Zhuang W, Chu Q, Yuan H, **Miao C**, et al. Towards intrinsic common discriminative features learning for face forgery detection using adversarial learning[C]//2022 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2022: 1-6.

基于无监督帧内不一致性感知的伪造人脸检测

- 设计动机：伪造过程中存在伪造区域和真实背景相互融合的步骤，这会产生帧内不一致性。通常帧内一致性感知学习需要额外的像素级伪造位置标签，然而像素级伪造位置标签是很难获取的。
- 核心技巧：无监督的帧内不一致性感知方法，在没有像素级监督的情况下，只利用视频级别的标签，学习不一致性感知的特征。




- 核心思路：基于异常检测的思路，在训练过程中逐步更新多元高斯分布估计来表示真/假图像的局部块特征，再根据特征与分布之间的距离获得伪造区域的伪标签。生成的伪造区域伪标签可以用于设计一致性约束，对 Transformer 的中间层注意力图进行块特征一致性学习。同时，为了进一步增强真/假分布之间的区分性和准确度，设计了分布中心性学习，约束高斯分布围绕均值的紧凑程度。

Zhuang W, Chu Q, Tan Z, Liu Q, Yuan H, **Miao C**, et al. UIA-ViT: Unsupervised inconsistency-aware method based on vision transformer for face forgery detection[C]//European Conference on Computer Vision (ECCV Oral), 2022: 391-407.

基于Transformer的特征补偿与聚合的伪造人脸检测

- 设计动机：
transformer缺少局部信息，以及不同网络层的特征表征不同的伪造痕迹。
- 核心技巧：构建局部补偿模块(LCB)和多头聚类映射模块(MCP)。
- 核心思路：提出了一种包含全局-局部交叉注意(GLCA)的局部补偿块(LCB)，以集中融合transformer的全局特征和CNN的局部特征。为了聚合所有层的特征以捕获全面的和多样的伪造缺陷，进一步提出了多头聚类映射(MCP)和频率引导的融合模块(FFM)，其中MCP将冗余特征集中到几个集中的簇中，FFM在频率线索的引导下对所有聚类特征进行交互。



Tan Z, Yang Z, **Miao C**, et al. Transformer-based feature compensation and aggregation for deepfake detection[J]. IEEE Signal Processing Letters (SPL), 2022, 29: 2183-2187.



多模态伪造检测与定位

多模态假新闻

➤ Weibo Dataset

- 在微博官方辟谣系统上抓取 2012 年 5 月到 2016 年 1 月的所有经过验证的虚假谣言帖子。
- 对于非谣言推文，使用新华社（中国权威新闻机构）验证的推文。

Statistics		Weibo
Training Set	Rumor	3749
	Non-rumor	3783
Testing Set	Rumor	1000
	Non-rumor	996
All		9528



(a) Top rumor examples



(b) Top non-rumor examples

多模态假新闻

➤ Twitter Dataset

- 17 个事件（或恶作剧）相关的推文共包含193个真实图像案例、218个误用（假）图像和2种误用视频的情况
- 总共6,225个真实推文和 9,404个虚假推文分别由5895个用户发布的真实推文, 9025个用户发布的虚假推文

ID	Name	I_R	T_R	U_R	I_F	T_F	U_F
E1	Hurricane sandy	148	4664	4446	62	5558	5432
E2	Boston marathon bombing	28	344	310	35	189	187
E3	Sochi olympics	–	–	–	26	274	252
E4	Bring back our girls	–	–	–	7	131	126
E5	MA flight 370	–	–	–	29	310	302
E6	Columbian chemicals	–	–	–	15	185	87
E7	Passport hoax	–	–	–	2	44	44
E8	Rock elephant	–	–	–	1	13	13
E9	Underwater bedroom	–	–	–	3	113	112
E10	Livr mobile app	–	–	–	4	9	9
E11	Pig fish	–	–	–	1	14	14
E12	Nepal earthquake	11	1004	934	21	356	343
E13	Solar eclipse	4	140	133	6	137	135
E14	Garissa attack	2	73	72	2	6	6
E15	Samurai and girl	–	–	–	4	218	212
E16	Syrian boy	–	–	–	1	1786	1692
E17	Varoufakis and ZDF	–	–	–	1	61	59
Total		193	6225	5895	220	9404	9025



Fig. 4 Types of fake: i reposting of real photograph depicting two Vietnamese siblings as being captured during the Nepal 2015 earthquakes; ii reposting of artwork as a photograph from Solar Eclipse of March 2015;

iii speculation of someone as being suspect of the Boston Marathon bombings in 2013; iv spliced sharks on a photograph captured during Hurricane Sandy in 2012

Detection and visualization of misleading content on Twitter. IJMIR (2018) 7:71–86

多模态假新闻

➤ Fakeddit Dataset

- 从 Reddit (社交新闻和讨论网站, 用户可以发布各种subreddit) 中获取数据集。包含来自 22 个不同 subreddit 的超过 100 万份用户发布内容。
- 收集了提交标题和图像、参与提交的用户所做的评论以及其他提交元数据, 包括分数、作者的用户名、subreddit 源、源域、评论数量以及赞成票比率。

Dataset Statistics	
Total samples	1,063,106
Fake samples	628,501
True samples	527,049
Multimodal samples	682,996
Subreddits	22
Unique users	358,504
Unique domains	24,203
Timespan	3/19/2008 - 10/24/2019
Mean words per submission	8.27
Mean comments per submission	17.94
Vocabulary size	175,566
Training set size	878,218
Validation set size	92,444
Released test set size	92,444
Unreleased set size	92,444



Maryland drive gets probation for Delaware crash that killed 5 NJ family members

True




New 'Natural Feeding' trend has parents puking on babies

Satire/Parody




Neuroscience Says Doing This 1 Thing Makes You Just as Happy as Eating 2,000 Chocolate Bars

Misleading Content




My plane hit an orca right after takeoff

Manipulated Content



Bowl of mussels

False Connection



I just thought that was sitting in the deli

Imposter Content

Fakeddit: A New Multimodal Benchmark Dataset for Fine-grained Fake News Detection. LREC 2020

多模态伪造

➤ DGM4

- 各种各样的deepfake detection和 text fake news detection方法被提出，但是他们只关注单一模态且只是二分类任务；
- 对跨模态的细微篡改线索缺少分析和推理。

- ✓ DGM4旨在不仅检测多模态媒体的真实性，还要对操纵内容进行定位（即图像边界框和文本标记），这需要对多模态媒体操纵进行更深入的推理。

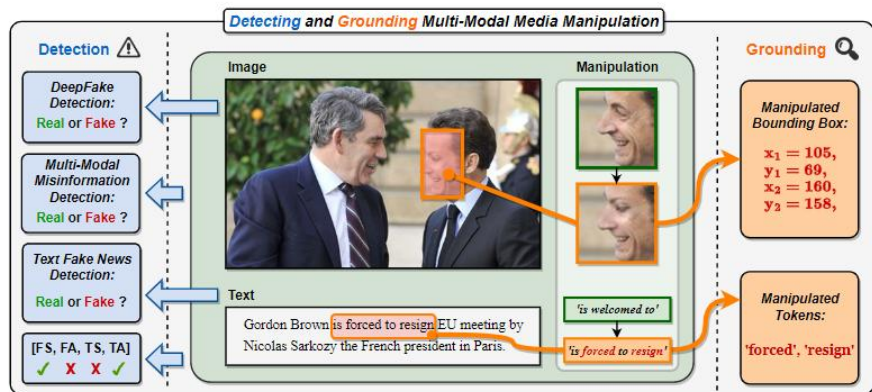



Figure 1. Different from existing single-modal forgery detection tasks, DGM⁴ not only performs real/fake classification on the input image-text pair, but also attempts to detect more fine-grained manipulation types and ground manipulated image bboxes and text tokens. They provide more comprehensive interpretation and deeper understanding about manipulation detection besides the binary classification. (FS: Face Swap Manipulation, FA: Face Attribute Manipulation, TS: Text Swap Manipulation, TA: Text Attribute Manipulation)

Table 1. Comparison of the proposed DGM⁴ with existing tasks related to image and text forgery detection

Problem Setting	Image Forgery		Text Forgery		Multi-Modal Forgery Detection
	Detection	Grounding	Detection	Grounding	
DeepFake Detection [30, 60]	✓	✗	✗	✗	✗
Text Fake News Detection [53, 58]	✗	✗	✓	✗	✗
Multi-Modal Misinformation Detection [1, 29]	✗	✗	✗	✗	✓
DGM ⁴	✓	✓	✓	✓	✓

基于模态特异性特征的多模态伪造检测和定位算法

- 设计动机：现有方法主要集中在融合视觉-语言特征，而忽视了模态特异性特征的重要性；
- 核心技巧：构建了一个基于Transformer的多模态操纵检测和定位框架。在保持多模态对齐能力的同时，同时探索模态特定特征；
- 核心思路：引入了视觉/语言预训练编码器和双分支交叉注意力（DCA）来提取和融合模态特异性特征。此外，设计了解耦的细粒度分类器（DFC）来增强模态特定特征的挖掘并减轻不同模态之间的竞争。此外，提出了一种隐式操纵查询（IMQ），它使用可学习的查询自适应地聚合每个模态内的全局上下文线索，从而改善对伪造细节的学习能力。



Wang J, Liu B, **Miao C**, et al. EXPLOITING MODALITY-SPECIFIC FEATURES FOR MULTI-MODAL MANIPULATION DETECTION AND GROUNDING[C]// ICASSP 2024.