

纳更多的具有相近概率的词，增加文本的丰富度，改善“枯燥无趣”。例如在图1.9 (b) 所示的例子中，我们若以 0.9 作为阈值，则就可以包含打架、睡觉等长颈鹿脖子鲜为人知的用途。

3. Temperature 机制

Top-K 采样和 Top-P 采样的随机性由语言模型输出的概率决定，不可自由调整。但在不同场景中，我们对于随机性的要求可能不一样。比如在开放文本生成中，我们更倾向于生成更具创造力的文本，所以我们需要采样具有更强的随机性。而在代码生成中，我们希望生成的代码更为保守，所以我们需要较弱的随机性。引入 Temperature 机制可以对解码随机性进行调节。Temperature 机制通过对 Softmax 函数中的自变量进行尺度变换，然后利用 Softmax 函数的非线性实现对分布的控制。设 Temperature 尺度变换的变量为 T 。

引入 Temperature 后，Top-K 采样的候选集的分布如下所示：

$$p(w_{i+1}^1, \dots, w_{i+1}^K) = \left\{ \frac{\exp(\frac{o_i[w_{i+1}^1]}{T})}{\sum_{j=1}^K \exp(\frac{o_i[w_{i+1}^j]}{T})}, \dots, \frac{\exp(\frac{o_i[w_{i+1}^K]}{T})}{\sum_{j=1}^K \exp(\frac{o_i[w_{i+1}^j]}{T})} \right\}. \quad (1.48)$$

引入 Temperature 后，Top-P 采样的候选集的分布如下所示：

$$p(w_{i+1}^1, \dots, w_{i+1}^{|S_p|}) = \left\{ \frac{\exp(\frac{o_i[w_{i+1}^1]}{T})}{\sum_{j=1}^{|S_p|} \exp(\frac{o_i[w_{i+1}^j]}{T})}, \dots, \frac{\exp(\frac{o_i[w_{i+1}^{|S_p|}]}{T})}{\sum_{j=1}^{|S_p|} \exp(\frac{o_i[w_{i+1}^j]}{T})} \right\}. \quad (1.49)$$

容易看出，当 $T > 1$ 时，Temperature 机制会使得候选集中的词的概率差距减小，分布变得更平坦，从而增加随机性。当 $0 < T < 1$ 时，Temperature 机制会使得候选集中的元素概率差距加大，强者越强，弱者越弱，概率高的候选词会容易被选到，从而随机性变弱。Temperature 机制可以有效的对随机性进行调节来满足不同的需求。

1.5 语言模型的评测

得到一个语言模型后，我们需要对其生成能力进行评测，以判断其优劣。评测语言模型生成能力的方法可以分为两类。第一类方法不依赖具体任务，直接通过语言模型的输出来评测模型的生成能力，称之为内在评测（Intrinsic Evaluation）。第二类方法通过某些具体任务，如机器翻译、摘要生成等，来评测语言模型处理这些具体生成任务的能力，称之为外在评测（Extrinsic Evaluation）。

1.5.1 内在评测

在内在评测中，测试文本通常由与预训练中所用的文本独立同分布的文本构成，**不依赖于具体任务**。最为常用的内部评测指标是困惑度（Perplexity）[10]。其度量了语言模型对测试文本感到“困惑”的程度。设测试文本为 $s_{test} = w_{1:N}$ 。语言模型在测试文本 s_{test} 上的困惑度 PPL 可由下式计算：

$$PPL(s_{test}) = P(w_{1:N})^{-\frac{1}{N}} = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i|w_{<i})}}。 \quad (1.50)$$

由上式可以看出，如果语言模型对测试文本越“肯定”（即生成测试文本的概率越高），则困惑度的值越小。而语言模型对测试文本越“不确定”（即生成测试文本的概率越低），则困惑度的值越大。由于测试文本和预训练文本同分布，预训练文本代表了我们要让语言模型学会生成的文本，如果语言模型在这些测试文本上越不“困惑”，则说明语言模型越符合我们对其训练的初衷。因此，困惑度可以一定程度上衡量语言模型的生成能力。

对困惑度进行改写，其可以改写成如下等价形式。

$$PPL(s_{test}) = \exp\left(-\frac{1}{N} \sum_{i=1}^N \log P(w_i|w_{<i})\right)。 \quad (1.51)$$

其中， $-\frac{1}{N} \sum_{i=1}^N \log P(w_i|w_{<i})$ 可以看作是生成模型生成的词分布与测试样本真实

的词分布间的交叉熵，即 $-\frac{1}{N} \sum_{i=1}^N \sum_{d=1}^{|D|} I(\hat{w}_d = w_i) \log o_{i-1}[w_i]$ ，其中 D 为语言模型所采用的词典。因为 $P(w_i|w_{<i}) \leq 1$ ，所以此交叉熵是生成模型生成的词分布的信息熵的上界，即

$$-\frac{1}{N} \sum_{i=1}^N P(w_i|w_{<i}) \log P(w_i|w_{<i}) \leq -\frac{1}{N} \sum_{i=1}^N \log P(w_i|w_{<i}). \quad (1.52)$$

因此，困惑度减小也意味着熵减，意味着模型“胡言乱语”的可能性降低。

1.5.2 外在评测

在外在评测中，测试文本通常包括该任务上的问题和对应的标准答案，其依赖于具体任务。通过外在评测，我们可以评判语言模型处理特定任务的能力。外在评测方法通常可以分为基于统计指标的评测方法和基于语言模型的评测方法两类。以下对此两类方法中的经典方法进行介绍。

1. 基于统计指标的评测

基于统计指标的方法构造统计指标来评测语言模型的输出与标准答案间的契合程度，并以此作为评测语言模型生成能力的依据。BLEU (BiLingual Evaluation Understudy) 和 ROUGE (Recall-Oriented Understudy for Gisting Evaluation) 是应用最为广泛的两种统计指标。其中，BLEU 是精度导向的指标，而 ROUGE 是召回导向的指标。以下分别对这两个指标展开介绍。

BLEU 被提出用于评价模型在机器翻译 (Machine Translation, MT) 任务上的效果 [6]。其在词级别上计算生成的翻译与参考翻译间的重合程度。具体地，BLEU 计算多层次 n-gram 精度的几何平均。设生成的翻译文本的集合为 $S_{gen} = \{S_{gen}^i\}_{i=1}^{|S_{gen}|}$ ，对应的参考翻译集合为 $S_{ref} = \{S_{ref}^i\}_{i=1}^{|S_{ref}|}$ ，其中， S_{gen}^i 与 S_{ref}^i 一一对应，且 $|S_{ref}| = |S_{gen}|$ 。原始的 n-gram 精度的定义如下：

$$Pr(g_n) = \frac{\sum_{i=1}^{|S_{gen}|} \sum_{g_n \in S_{gen}^i} Count_{match}(g_n, S_{ref}^i)}{\sum_{i=1}^{|S_{gen}|} \sum_{g_n \in S_{gen}^i} Count(g_n)}. \quad (1.53)$$

其中, g_n 代表 n -gram。上式的分子计算了生成的翻译与参考翻译的重合的 n -gram 的个数, 分母计算了生成的翻译中包含的 n -gram 的总数。例如, MT 模型将“大语言模型”翻译成英文, 生成的翻译为“big language models”, 而参考文本为“large language models”。当 $n = 1$ 时, $Pr(g_1) = \frac{2}{3}$ 。当 $n = 2$ 时, $Pr(g_2) = \frac{1}{2}$ 。

基于 n -gram 精度, BLEU 取 N 个 n -gram 精度的几何平均作为评测结果:

$$BLEU = \sqrt[N]{\prod_{n=1}^N Pr(g_n)} = \exp \left(\frac{1}{N} \sum_{n=1}^N \log Pr(g_n) \right). \quad (1.54)$$

例如, 当 $N = 3$ 时, BLEU 是 unigram 精度, bigram 精度, trigram 精度的几何平均。在以上原始 BLEU 的基础上, 我们还可以通过不同的 n -gram 精度进行加权或不同的文本长度设置惩罚项来对 BLEU 进行调整, 从而得到更为贴近人类评测的结果。

ROUGE 被提出用于评价模型在摘要生成 (Summarization) 任务上的效果 [13]。常用的 ROUGE 评测包含 ROUGE-N, ROUGE-L, ROUGE-W, 和 ROUGE-S 四种。其中, ROUGE-N 是基于 n -gram 的召回指标, ROUGE-L 是基于最长公共子序列 (Longest Common Subsequence, LCS) 的召回指标。ROUGE-W 是在 ROUGE-L 的基础上, 引入对 LCS 的加权操作后的召回指标。ROUGE-S 是基于 Skip-bigram 的召回指标。下面给出 ROUGE-N, ROUGE-L 的定义。ROUGE-W 和 ROUGE-S 的具体计算方法可在 [13] 中找到。

ROUGE-N 的定义如下:

$$ROUGE-N = \frac{\sum_{s \in S_{ref}} \sum_{g_n \in s} Count_{match}(g_n, s_{gen})}{\sum_{s \in S_{ref}} \sum_{g_n \in s} Count(g_n)}. \quad (1.55)$$

ROUGE-L 的定义如下:

$$ROUGE-L = \frac{(1 + \beta^2) R_r^g R_g^r}{R_r^g + \beta^2 R_g^r}. \quad (1.56)$$

其中,

$$R_r^g = \frac{LCS(s_{ref}, s_{gen})}{|s_{ref}|}, \quad (1.57)$$

$$R_g^r = \frac{LCS(s_{ref}, s_{gen})}{|s_{gen}|}, \quad (1.58)$$

$LCS(s_{ref}, s_{gen})$ 是模型生成的摘要 s_{gen} 与参考摘要 s_{ref} 间的最大公共子序列的长度, $\beta = R_g^r / R_r^g$ 。

基于统计指标的评测方法通过对语言模型生成的答案和标准答案间的重叠程度进行评分。这样的评分无法完全适应生成任务中表达的多样性, 与人类的评测相差甚远, 尤其是在生成的样本具有较强的创造性和多样性的时候。为解决此问题, 可以在评测中引入一个其他语言模型作为“裁判”, 利用此“裁判”在预训练阶段掌握的能力对生成的文本进行评测。下面对这种引入“裁判”语言模型的评测方法进行介绍。

2. 基于语言模型的评测

目前基于语言模型的评测方法主要分为两类: (1) 基于上下文词嵌入 (Contextual Embeddings) 的评测方法; (2) 基于生成模型的评测方法。典型的基于上下文词嵌入的评测方法是 BERTScore [24]。典型的基于生成模型的评测方法是 G-EVAL [14]。与 BERTScore 相比, G-EVAL 无需人类标注的参考答案。这使其可以更好的适应到缺乏人类标注的任务中。

BERTScore 在 BERT 的上下文词嵌入向量的基础上, 计算生成文本 s_{gen} 和参考文本 s_{ref} 间的相似度来对生成样本进行评测。BERT 将在第二章给出详细介绍。设生成文本包含 $|s_{gen}|$ 个词, 即 $s_{gen} = \{w_g^i\}_{i=1}^{|s_{gen}|}$ 。设参考文本包含 $|s_{ref}|$ 个词, 即 $s_{ref} = \{w_r^i\}_{i=1}^{|s_{ref}|}$ 。利用 BERT 分别得到 s_{gen} 和 s_{ref} 中每个词的上下文词嵌入向量, 即 $v_g^i = BERT(w_g^i | s_{gen})$, $v_r^i = BERT(w_r^i | s_{ref})$ 。利用生成文本和参考文本的词嵌入向量集合 $v_{gen} = \{v_g^i\}_{i=1}^{|v_{gen}|}$ 和 $v_{ref} = \{v_r^i\}_{i=1}^{|v_{ref}|}$ 便可计算 BERTScore。BERTScore

从精度 (Precision), 召回 (Recall) 和 F1 量度三个方面对生成文档进行评测。其定义分别如下:

$$P_{BERT} = \frac{1}{|v_{gen}|} \sum_{i=1}^{|v_{gen}|} \max_{v_r \in v_{ref}} v_g^i \top v_r^i, \quad (1.59)$$

$$R_{BERT} = \frac{1}{|v_{ref}|} \sum_{i=1}^{|v_{ref}|} \max_{v_g \in v_{gen}} v_r^i \top v_g^i, \quad (1.60)$$

$$F_{BERT} = \frac{2P_{BERT} \cdot R_{BERT}}{P_{BERT} + R_{BERT}}. \quad (1.61)$$

相较于统计评测指标, BERTScore 更接近人类评测结果。但是, BERTScore 依赖于人类给出的参考文本。这使其无法应用于缺乏人类标注样本的场景中。得益于生成式大语言模型的发展, G-EVAL 利用 GPT-4 在没有参考文本的情况下对生成文本进行评分。G-EVAL 通过提示工程 (Prompt Engineering) 引导 GPT-4 输出评测分数。Prompt Engineering 将在本书第三章进行详细讲解。

如下图所示, G-EVAL 的 Prompt 分为三部分: (1) 任务描述与评分标准; (2) 评测步骤; (3) 输入文本与生成的文本。在第一部分中, 任务描述指明需要的评测的任务式什么 (如摘要生成), 评分标准给出评分需要的范围, 评分需要考虑的因素等内容。第二部分的评测步骤是在第一部分内容的基础上由 GPT-4 自己生成的思维链 (Chain-of-Thoughts, CoT)。本书的第三章将对思维链进行详细讲解。第三部分的输入文本与生成的文本是源文本和待评测模型生成的文本。例如摘要生成任务中的输入文本是原文, 而生成的文本就是生成摘要。将上述三部分组合在一个 prompt 里面然后输入给 GPT-4, GPT-4 便可给出对应的评分。直接将 GPT-4 给出的得分作为评分会出现区分度不够的问题, 因此, G-EVAL 还引入了对所有可能得分进行加权平均的机制来进行改进 [14]。




图 1.10: G-EVAL 评测流程。

除 G-EVAL 外，近期还有多种基于生成模型的评测方法被提出 [12]。其中典型的有 InstructScore [23]，其除了给出数值的评分，还可以给出对该得分的解释。基于生成模型的评测方法相较于基于统计指标的方法和基于上下文词嵌入的评测方法而言，在准确性、灵活性、可解释性等方面都具有独到的优势。可以预见，未来基于生成模型的评测方法将得到更为广泛的关注和应用。

参考文献

- [1] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. *Layer Normalization*. 2016. arXiv: 1607.06450.
- [2] Samy Bengio et al. “Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks”. In: *NeurIPS*. 2015.
- [3] Tom B. Brown et al. “Language Models are Few-Shot Learners”. In: *NeurIPS*. 2020.
- [4] Junyoung Chung et al. *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling*. 2014. arXiv: 1412.3555.
- [5] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *NAACL-HLT*. 2019.
- [6] Markus Freitag, David Grangier, and Isaac Caswell. “BLEU might be Guilty but References are not Innocent”. In: *EMNLP*. 2020.
- [7] Mor Geva et al. “Transformer Feed-Forward Layers Are Key-Value Memories”. In: *EMNLP*. 2021.

- [8] Sepp Hochreiter and Jürgen Schmidhuber. “Long Short-Term Memory”. In: *Neural Computing* 9.8 (1997), pp. 1735–1780.
- [9] Ari Holtzman et al. “The Curious Case of Neural Text Degeneration”. In: *ICLR*. 2020.
- [10] F. Jelinek et al. “Perplexity—a measure of the difficulty of speech recognition tasks”. In: *The Journal of the Acoustical Society of America* 62 (1997), S63–S63.
- [11] Dan Jurafsky and James H. Martin. *Speech and language processing: an introduction to natural language processing, computational linguistics, and speech recognition, 2nd Edition*. Prentice Hall series in artificial intelligence. Prentice Hall, Pearson Education International, 2009. ISBN: 9780135041963.
- [12] Zhen Li et al. *Leveraging Large Language Models for NLG Evaluation: Advances and Challenges*. 2024. arXiv: [2401.07103](#).
- [13] Chin-Yew Lin. “Rouge: A package for automatic evaluation of summaries”. In: *ACL*. 2004.
- [14] Yang Liu et al. “GpTeval: Nlg evaluation using gpt-4 with better human alignment”. In: *EMNLP*. 2023.
- [15] Christopher D. Manning and Hinrich Schütze. *Foundations of statistical natural language processing*. MIT Press, 2001. ISBN: 978-0-262-13360-9.
- [16] OpenAI. *GPT-4 Technical Report*. 2024. arXiv: [2303.08774](#).
- [17] Razvan Pascanu, Tomás Mikolov, and Yoshua Bengio. “On the difficulty of training recurrent neural networks”. In: *ICML*. 2013.
- [18] Colin Raffel et al. “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”. In: *Journal of Machine Learning Research* 21 (2020), 140:1–140:67.
- [19] Ashwin K. Vijayakumar et al. “Diverse Beam Search: Decoding Diverse Solutions from Neural Sequence Models”. In: *AAAI*. 2018.
- [20] Joseph Weizenbaum. “ELIZA - a computer program for the study of natural language communication between man and machine”. In: *Communications Of The ACM* 9.1 (1966), pp. 36–45.
- [21] Ronald J. Williams and David Zipser. “A Learning Algorithm for Continually Running Fully Recurrent Neural Networks”. In: *Neural Computing* 1.2 (1989), pp. 270–280.

- [22] Shufang Xie et al. *ResiDual: Transformer with Dual Residual Connections*. 2023. arXiv: [2304.14802](#).
- [23] Wenda Xu et al. “INSTRUCTSCORE: Towards Explainable Text Generation Evaluation with Automatic Feedback”. In: *EMNLP*. 2023.
- [24] Tianyi Zhang et al. “BERTScore: Evaluating Text Generation with BERT”. In: *ICLR*. 2020.



