

中获取相应的输出分数 $s_{\mathcal{M}}, s_{\mathcal{M}+}, s_{\mathcal{M}-}$ 。通过下式调整目标模型的输出分数 $\tilde{s}$:

$$\tilde{s} = s_{\mathcal{M}} + s_{\mathcal{M}+} - s_{\mathcal{M}-}, \quad (4.3)$$

然后, 使用 $\text{softmax}(\cdot)$ 对其进行归一化, 得到输出概率分布,

$$p_{\tilde{\mathcal{M}}}(X_t | x_{<t}) = \text{softmax}(\tilde{s}), \quad (4.4)$$

最后, 在该分布中采样得到下一个词的预测结果。

在实际使用中, 通常专家模型是较小的模型 (例如, LLaMA-7B), 而代理模型则是更大的模型 (例如, LLaMA-13B 或 LLaMA-70B)。通过代理微调, 我们将较小模型中学习到的知识, 以一种解码时约束的方式迁移到比其大得多的模型中, 大幅节省了计算成本。同时, 由于仅需要获取模型的输出分布, 而不需要原始的模型权重, 因此该方法对于黑盒模型同样适用。

本节介绍了三种主要的参数附加方法, 分别通过加在输入、加在模型以及加在输出三种方式实现。总的来说, 这几类方法都是提升预训练语言模型性能的有效手段, 它们各有优势。加在输入的方法通过在输入序列中添加可学习的张量, 对模型本身的结构修改较小, 有更好的灵活性。加在模型的方法保持了原始预训练模型的参数, 在泛化能力上表现更佳。加在输出的方法则能够以更小的代价驱动更大参数量的黑盒模型, 带来更实际的应用前景。

4.3 参数选择方法

参数选择方法 (Parameter Selection Methods) 选择性的对预训练模型中的某个参数子集进行微调。和参数附加方法不同的是, 参数选择方法无需向模型添加额外的参数, 避免了在推理阶段引入额外的计算成本。通常, 参数选择方法分为两类: 基于规则的方法和基于学习的方法。

4.3.1 基于规则的方法

基于规则的方法根据人类专家的经验，确定哪些参数应该被更新。基于规则的方法中最具代表性的方法是 BitFit [50]。BitFit 通过仅优化神经网络中的每一层的偏置项 (Biases) 以及任务特定的分类头来实现参数高效微调。由于偏置项在模型总参数中所占比例极小 (约 0.08%-0.09%)，BitFit 有极高的参数效率。尽管只微调少量参数，BitFit 依然能在 GLUE Benchmark [44] 上与全量微调相媲美，甚至在某些任务上表现更好。此外，BitFit 方法相比全量微调允许使用更大的学习率，因此该方法整体优化过程更稳定。然而，该方法仅在小模型 (如 BERT、RoBERT 等) 上进行验证性能，在更大模型上的性能表现如何尚且未知。

除 BitFit 以外，还有一些其他基于规则的方法通过仅微调特定的 Transformer 层来提高参数效率。例如，Lee 等人 [22] 提出，仅对 BERT 和 RoBERTa 的最后四分之一层进行微调，便能实现完全参数微调 90% 的性能。PaFi [26] 选择具有最小绝对值的模型参数作为可训练参数。

4.3.2 基于学习的方法

基于学习的方法在模型训练过程中自动地选择可训练的参数子集。其中，最为典型方法是 Child-tuning [49]。其通过**梯度掩码矩阵**策略实现仅对选中的子网络进行梯度更新，而屏蔽子网络梯度以外的梯度，从而实现对微调参数的选择，达到参数高效微调的目的。具体而言，假设 $\mathbf{W}_t$ 是第 t 轮迭代的参数矩阵，我们引入了一个与 $\mathbf{W}_t$ 同维度的 0-1 掩码矩阵 $\mathbf{M}_t$ ，用于选择第 t 轮迭代的子网络 $\mathbf{C}_t$ ，仅更新该子网络的参数，其定义如下：

$$\mathbf{M}_t^{(i)} = \begin{cases} 1, & \text{if } \mathbf{W}_t^{(i)} \in \mathbf{C}_t \\ 0, & \text{if } \mathbf{W}_t^{(i)} \notin \mathbf{C}_t. \end{cases} \quad (4.5)$$

其中, $\mathbf{M}_t^{(i)}$ 和 $\mathbf{W}_t^{(i)}$ 分别是矩阵 $\mathbf{M}_t$ 和 $\mathbf{W}_t$ 在第 t 轮迭代的第 i 个元素。此时, 梯度更新公式为:

$$\mathbf{W}_{t+1} = \mathbf{W}_t - \eta \left(\frac{\partial \mathcal{L}(\mathbf{W}_t)}{\partial \mathbf{W}_t} \odot \mathbf{M}_t \right), \quad (4.6)$$

Child-tuning 提供了两种生成子网络掩码 $\mathbf{M}$ 的方式, 由此产生两种变体模型: Child-tuning_F 和 Child-tuning_D。Child-tuning_F 是一种**任务无关**的变体, 它在不依赖任何下游任务数据的情况下选择子网络。在每次迭代时, Child-tuning_F 从伯努利分布中抽取 0-1 掩码, 生成梯度掩码 $\mathbf{M}_t$:

$$\mathbf{M}_t \sim \text{Bernoulli}(p_F), \quad (4.7)$$

其中, p_F 是伯努利分布的概率, 表示子网络的比例。此外, Child-tuning_F 通过引入噪声来对全梯度进行正则化, 从而防止小数据集上的过拟合, 并提高泛化能力。

Child-tuning_D 是一种**任务驱动**的变体, 它利用下游任务数据来选择与任务最相关的子网络。具体来说, Child-tuning_D 使用费舍尔信息矩阵 (FIM) 来估计特定任务相关参数的重要性。具体地, 对于给定的任务训练数据 $\mathcal{D}$, 模型的第 i 个参数矩阵 $W^{(i)}$ 的费舍尔信息估计为:

$$F^{(i)}(W) = \frac{1}{|\mathcal{D}|} \sum_{j=1}^{|\mathcal{D}|} \left(\frac{\partial \log p(Y_j | X_j; W)}{\partial W^{(i)}} \right)^2, \quad (4.8)$$

其中, X_i 和 Y_i 分别表示第 i 个样本的输入和输出, $\log p(Y_i | X_i; W)$ 是对数似然概率, 通过计算损失函数对参数 $W^{(i)}$ 的梯度得到。通常, 我们假设参数对目标任务越重要, 它的费舍尔信息的值就越高。因此, 可以根据费舍尔信息来选择子网络, 子网络 $\mathbf{C}$ 由具有最高费舍尔信息的参数组成。选择子网络参数的步骤如下: 1) 计算每个参数的费舍尔信息值; 2) 对这些费舍尔信息值进行排序; 3) 选择前 p_D 比例的参数作为子网络 $\mathbf{C}$ 。确定子网络后, 生成相应的掩码矩阵完成模型训练。

Child-tuning 通过梯度屏蔽减少了计算负担, 同时减少了模型的假设空间, 降低了模型过拟合的风险。然而, 子网络的选择需要额外的计算代价, 特别是在任